

中国科学技术大学

硕士学位论文



基于融合特征的加密流量分类方法 研究

作者姓名：

学科专业： 计算机科学与技术

导 师：

完成时间： 二〇二六年三月二十八日

University of Science and Technology of China

A dissertation for master's degree



Research on Encryption Traffic Classification Method Based on Fusion Features

Author:

Speciality: Computer Science and Technology

Supervisor:

Completion date: March 28, 2026

中国科学技术大学学位论文原创性声明

本人声明所呈交的学位论文，是本人在导师指导下进行研究工作所取得的成果。除已特别加以标注和致谢的地方外，论文中不包含任何他人已经发表或撰写过的研究成果。与我一同工作的同志对本研究所做的贡献均已在论文中作了明确的说明。

作者签名：_____

签字日期：_____

中国科学技术大学学位论文授权使用声明

作为申请学位的条件之一，学位论文著作权拥有者授权中国科学技术大学拥有学位论文的部分使用权，即：学校有权按有关规定向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅，可以将学位论文编入《中国学位论文全文数据库》等有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存、汇编学位论文。本人提交的电子文档的内容和纸质论文的内容相一致。

控阅的学位论文在解除后也遵守此规定。

☒ 公开 ☐ 控阅（____年）

作者签名：_____

导师签名：_____

签字日期：_____

签字日期：_____

摘要

识别流量类型是网络研究的一项基本且关键的能力，对服务质量控制、安全检测等应用至关重要。随着用户隐私意识增强，SSL/TLS、VPN 和 Tor 等加密工具普及（如美国加密流量占比从 2017 年 55% 升至 2025 年 94%），传统基于端口和深度包检测（DPI）的方法因无法解析加密的数据包载荷而失效。机器学习方法虽利用流统计特征实现分类，但依赖人工特征工程，泛化能力有限且实施成本高。深度学习技术通过端到端学习范式突破上述限制：可直接处理原始流量数据，自动提取特征，支持早期分类，并减少对专家知识的依赖。然而，现有深度学习方案多存在显著局限：仅根据流级别或包级别特征来分析和识别流量，而忽略了另一维度所包含的流量特征，未能融合双维度信息；并且，在包级别的处理中，还存在包头和有效载荷的混合使用的情况，既未区分功能差异，又因使用有效载荷数据而损害用户的隐私权益。因此，研究一种融合流级别与包级别特征，且仅使用 IP 数据包头，不涉及数据包有效载荷的基于深度学习的融合加密流量分类方法，对提升网络安全和服务质量具有重要价值。

本文的主要工作内容如下：

(1) 在本文中，我们提出了一种基于 BYOL 模型的流级别特征分类方法。我们的目的是仅使用数据流的早期的数据包长度序列，就能够实现有效的早期流量分类。该方案通过对数据包长度序列进行截取，然后对同一个长度序列进行两种差异化增强，然后分别输入 BYOL 模型的在线网络和目标网络，从而提取出两种增强变体之间不变的，具有鲁棒性的流级别特征。实验表明，与不具有对比学习机制的传统深度学习方法相比，我们的方法在多个加密流量数据集上实现了更高的分类准确率，提升约 5%。

(2) 为了进一步提升分类效果，本文设计了一种基于 n-gram 技术的包级别特征提取方法，仅使用 IP 数据包头，而不涉及数据包的有效载荷，通过对 IP 包头数据进行不同窗口大小的结合，有效地学习了包头字段的字节组合与顺序特征。并且通过动态权重的特征融合机制，将流级别和包级别的特征进行融合，实现了特征间非线性关系的有效建模，并在多个加密流量数据集上进行了验证。实验结果表明，融合了流级别和包级别特征的分类方法显著优于仅使用单一维度特征的方法，在加密流量分类的准确率上提升约 5% – 9%。与当前具有代表性的双模态方法相比，在准确性方面提升约 4%

关键词：加密流量；流量分类；自监督学习；特征融合

ABSTRACT

Identifying traffic types is a fundamental and crucial capability in network research, essential for applications such as Quality of Service (QoS) control and security testing. With increasing user privacy awareness and the widespread adoption of encryption tools such as SSL/TLS, VPNs, and Tor (e.g., the percentage of encrypted traffic in the US is projected to rise from 55% in 2017 to 94% in 2025), traditional port-based and deep packet inspection (DPI) methods become ineffective due to their inability to parse encrypted packet payloads. While machine learning methods utilize flow statistics for classification, they rely on manual feature engineering, resulting in limited generalization capabilities and high implementation costs. Deep learning technology overcomes these limitations through an end-to-end learning paradigm: it can directly process raw traffic data, automatically extract features, support early classification, and reduce reliance on expert knowledge. However, existing deep learning solutions often have significant limitations: they analyze and identify traffic based solely on flow-level or packet-level features, neglecting traffic features contained in the other dimension and failing to integrate dual-dimensional information. Furthermore, in packet-level processing, there is a situation where headers and payloads are used interchangeably, failing to distinguish functional differences and infringing on user privacy due to the use of payload data. Therefore, researching a deep learning-based fusion encrypted traffic classification method that integrates flow-level and packet-level features, using only IP packet headers and excluding packet payloads, is of significant value for improving network security and service quality.

The main contributions of this paper are as follows:

(1) In this paper, we propose a flow-level feature classification method based on the BYOL model. Our goal is to achieve effective early traffic classification using only the early packet length sequence of the data flow. This scheme extracts robust flow-level features invariant between the two enhancement variants by truncating the packet length sequence and then applying two differential enhancements to the same length sequence, which are then input into the online and target networks of the BYOL model, respectively. Experiments show that our method achieves higher classification accuracy on multiple encrypted traffic datasets compared to traditional methods without a contrastive learning mechanism.

(2) To further improve classification performance, this paper designs a packet-level

feature extraction method based on n-gram technology. This method uses only the IP packet header, excluding the packet payload. By combining IP packet header data with different window sizes, it effectively learns the byte combination and order features of the header fields. Furthermore, through a dynamic weighted feature fusion mechanism, flow-level and packet-level features are fused, effectively modeling the nonlinear relationship between features. This method has been validated on multiple encrypted traffic datasets. Experimental results show that the classification method fusing flow-level and packet-level features significantly outperforms methods using only single-dimensional features, further improving the accuracy of encrypted traffic classification.

KEY WORDS: Encrypted traffic, Traffic classification, Self-Supervised Learning, Feature fusion

目录

第 1 章 绪论	1
1.1 研究背景及意义	1
1.2 国内外研究现状	2
1.2.1 基于载荷检测的方法	3
1.2.2 基于传统机器学习的方法	3
1.2.3 基于深度学习的方法	4
1.3 研究内容	6
1.4 章节安排	7
第 2 章 相关理论概述	9
2.1 网络流量分类理论	9
2.1.1 端口检测	9
2.1.2 深度包检测	9
2.1.3 传统机器学习方法	10
2.1.4 基于深度学习的方法	10
2.2 深度学习概述	11
2.2.1 卷积神经网络	11
2.2.2 激活函数	14
2.2.3 损失函数	16
2.2.4 残差神经网络	18
2.2.5 注意力机制	19
2.3 自监督学习	20
2.3.1 对比学习	20
2.3.2 数据增强	21
2.4 本章小结	22
第 3 章 基于 BYOL 模型的流级特征分类方法	23
3.1 系统模型	23
3.2 增强函数	24
3.2.1 增强函数 1: 噪声注入	24
3.2.2 增强函数 2: 尺度缩放与随机遮蔽	25
3.3 模型架构	26
3.3.1 编码器	26

3.3.2	投影器和预测器	27
3.3.3	损失函数	28
3.3.4	指数移动平均值 (EMA) 更新机制	29
3.4	训练优化	29
3.4.1	学习率调度与 AdamW 优化	29
3.4.2	针对抖动的回溯策略	29
3.5	实验设计与结果分析	30
3.5.1	实验环境	30
3.5.2	数据集介绍与预处理	30
3.5.3	评价指标	33
3.5.4	参数设置	33
3.5.5	对比算法	35
3.5.6	实验结果分析	35
3.6	本章小结	37
第 4 章	基于融合特征的分类方法	38
4.1	系统模型	39
4.2	包级别特征提取	39
4.2.1	报文首部截取与预处理	39
4.2.2	N-gram 嵌入处理	40
4.3	交叉注意力特征融合机制	42
4.3.1	线性投影与空间对齐	42
4.3.2	交叉注意力流	42
4.4	深度残差分类器	44
4.4.1	输入层	45
4.4.2	深层残差主干网络	45
4.4.3	输出层逻辑	46
4.5	训练优化	46
4.5.1	学习率调度	46
4.6	实验设计与结果分析	46
4.6.1	参数设置	47
4.6.2	对比算法	47
4.6.3	实验结果分析	48
4.7	本章小结	50

第 5 章 总结与展望	52
5.1 本文工作总结	52
5.2 未来展望	53
第 6 章 引用文献的标注	55
6.1 顺序编码制	55
6.1.1 角标数字标注法	55
6.1.2 数字标注法	55
6.2 著者-出版年制标注法	55
参考文献	56
在读期间取得的科研成果	58

插图和附表清单

图 1.1	加密协议使用情况	1
图 1.2	研究内容结构图	6
图 2.1	卷积神经网络结构	12
图 2.2	卷积运算过程	13
图 2.3	两种池化方式	14
图 2.4	常见的激活函数图像	15
图 2.5	注意力机制处理过程	20
图 2.6	对比学习过程	21
图 3.1	BYOL 模型框架	23
图 3.2	数据包序列变化	24
图 3.3	编码器结构	26
图 3.4	数据预处理流程	32
图 4.1	两个混淆矩阵	38
图 4.2	n-gram 嵌入处理	41
图 4.3	交叉注意力机制	43
图 4.4	分类器结构	44
图 4.5	三种模型的混淆矩阵	50
表 2.1	常见激活函数的公式	15
表 2.2	常见损失函数的公式	17
表 3.1	实验环境设置	30
表 3.2	数据集内容	31
表 3.3	模型及训练参数设置	34
表 3.4	不同数据集上的对比实验结果	36
表 4.1	IP 数据报头结构	40
表 4.2	模型及训练参数设置	47
表 4.3	不同数据集上的对比实验结果	49

第 1 章 绪论

1.1 研究背景及意义

识别网络流量类型是开展网络空间安全研究与管理的一项基础且核心的能力。流量分类旨在将复杂多变的网络数据流准确归类至其对应的特定业务类别中，这对于实现服务质量优化、差异化计费、网络资源规划、恶意代码识别以及入侵检测等关键应用具有不可替代的支撑作用。

随着用户隐私保护意识的显著提升，加密通信协议已逐渐成为互联网流量的主导载体。根据 Firefox 的统计数据 [1]，美国互联网用户利用 SSL/TLS 安全协议进行通信的比例已从 2017 年的 55% 激增至 2024 年的 94%。与此同时，虚拟专用网络（VPN）和洋葱路由（Tor）等匿名化技术的广泛普及，进一步强化了网络通信的隐蔽性。在此趋势下，如何在不破坏端到端加密原则的前提下实现精准的流量分类，已成为保障网络安全供给与提升用户体验质量的关键技术。

Percentage of Web Pages Loaded by Firefox Using HTTPS

(14-day moving average, source: [Firefox Telemetry](#))




图 1.1 加密协议使用情况

早期的流量分类方案主要依赖于端口识别技术和深度包检测技术（Deep Packet Inspection, DPI）[2-4]。基于端口的方法通过匹配传输层协议端口与应用服务的对应关系进行识别，但随着动态端口协商及端口转发技术的广泛应用，该方法已逐渐失效。DPI 技术通过解析 IP 数据包的完整载荷以提取特征，然而在加密环境下，数据包载荷呈现为高熵的乱序字节序列，DPI 因无法穿透加密层获取明文特征，同样面临严峻的失效困境。

人工智能技术的进步为加密流量分类注入了新的生命力，主要围绕着传统

机器学习和深度学习算法的应用。基于机器学习的方法通常基于人工预设的统计特征构建流量特征，如数据包路径签名、数据包到达时间和大小以及累积数据包大小等，并且人工选择性能最佳的分类器对其进行分类。然而，机器学习方法的性能高度依赖于特征工程的质量，即为每个特定的加密流量协议或工具选择最优特征，而选择优质的特征表示要求研究者具备深厚的领域专家知识。此外，由于人工提取的特征往往针对特定协议设计，其泛化能力较差，难以适应现网中层出不穷的新型加密工具与协议。在真实的网络场景中，为不同工具或协议生成的各类加密流量训练和实施不同的基于机器学习的加密流量分类方法既耗时又难以实现。

作为机器学习的一个分支，深度学习在加密流量分类领域展现出巨大的潜力。深度学习技术的核心优势在于：模型能够直接从原始流量数据中自动执行多维度的表征学习，消除了对复杂特征工程的依赖。且相比于依赖完整流统计信息的机器学习方法，深度学习模型能够捕捉报文交互初期的细微特征，从而在流量会话早期即完成识别。此外，深度学习采用端到端的学习范式，通过深层神经网络架构，直接从原始输入数据学习以产生期望的输出，绕过了将问题分解为特征选择和分类等子问题的传统做法，能够更全面地挖掘流量数据中隐含的复杂关联模式，这一特性使深度学习算法能够全面地处理流量分类任务相关的复杂非线性问题。

尽管基于深度学习的方法已取得显著进展，但通过对现有主流算法的调研发现，仍存在许多有待解决的问题。首先多数算法倾向于单一维度分析，仅关注由包长度序列构成的流级别特征，或仅提取数据包内容构造包级别特征，未能充分挖掘跨维度特征间的协同表征能力，使得流量特征表示不充分。其次，部分研究在提取包级别特征时，未对报文首部与有效载荷的内容进行功能解耦，将其作为统一整体处理，忽略了两者在协议语义与信息载荷上的显著差异。最后，部分模型对有效载荷数据的深度依赖不仅增加了计算负载，也可能在处理敏感数据时违反用户隐私保护原则。综上所述，虽然基于深度学习的加密流量分类已成为主流研究方向，但如何高效提取具备泛化能力的特征，并充分利用多维度流量信息，仍是当前面临的核心挑战。

1.2 国内外研究现状

随着全球互联网信息化进程的加速以及数字经济的蓬勃发展，网络流量的爆发式增长使得流量分类技术成为网络管理、服务质量保障及网络安全监管领域的核心课题。经过数十年的演进，流量分类技术已从早期的简单匹配发展为如今基于人工智能的高度自动化识别。本文将从基于载荷检测、基于传统机器学习

以及基于深度学习三个维度，对国内外现有的研究成果进行介绍。

1.2.1 基于载荷检测的方法

基于载荷检测的流量分类方法，也称为深度包检测（DPI），该技术的核心逻辑在于对数据包的应用层载荷进行拆解，并将其内容与预定义的协议特征签名进行模式匹配 [5]。常用的高性能 DPI 库包括 libprotoident、OpenDPI 和 nDPI。其中，nDPI 通过内置针对 HTTP、FTP 等主流协议的专用解码器，实现流量识别 [6]。除有效载荷内容外，部分 DPI 方案也会结合报文首部字段进行辅助判断，其中最常用的字段是端口号。例如，目的地为 80 端口的数据包通常会被优先分流至 HTTP 解析模块 [7-8]。然而，这种方法在端口动态分配和通用通信协议端口的情况下会失效。

DPI 技术目前在实际部署中面临严峻挑战。首先是计算开销问题，由于涉及海量字符串的逐一比对，其处理性能往往难以匹配高速骨干网的需求。尽管 Khandait 等人提出了一种基于 DPI 的网络流量分类方法，使用启发式方法，通过单次扫描流载荷即可对网络流进行分类，实现了次线性搜索复杂度，但在处理大规模并发流量时依然压力显著 [9]。其次是局限性与合规性问题，随着 SSL/TLS 加密协议的普及以及各类私有协议的兴起，载荷内容变得不再透明，导致特征匹配机制失效。此外，深度的有效载荷提取往往触及用户隐私保护的法律红线，限制了其在特定场景下的应用 [10]。

1.2.2 基于传统机器学习的方法

随着机器学习技术的出现，研究者开始转向基于统计特征的机器学习方法。此类方法的核心在于特征工程，即通过人工经验提取流量的统计属性，并利用监督学习算法构建分类器，其分类准确性的最关键因素变成了如何构造足够有效的特征并选择性能最优的分类器。

Taylor 等人开发的 AppScanner 利用随机森林算法对流数据的统计特征进行建模，实现了对移动端流量的有效区分 [11]。Liu 等人提出了一种多属性马尔可夫概率模型，该模型整合了消息类型序列和数据包长度，用于对流量应用进行分类 [12]。Ede 等人提出了一种名为 FlowPrint 的移动应用识别方法，通过半监督学习手段，自动查找网络流量中与目标相关的特征之间的时间相关性，并利用这些相关性生成应用指纹 [13]。Taylor 等人探讨了被动窃听者如何通过分析智能手机应用传输的网络流量来对其进行识别。尽管数据包的有效载荷被 SSL/TLS 加密所隐藏，利用基于数据包大小和方向等侧信道数据仍可以识别智能手机应用。此外还进一步研究了应用程序指纹如何随时间、跨设备以及跨不同版本的应用程序而变化 [14]。Shen 等人提出了一种名为 FineWP 的网页指纹识别方法，利用

双向客户端-服务器交互中数据包的长度信息提取出作为网页指纹识别的独特特征,并将其与上行主导阶段的数据包位置相结合,随后输入到随机森林、决策树和 k 近邻等机器学习算法中以创建细粒度的网页指纹 [15]。Saber 等人提出了一种基于主成分分析的方法用于流量分类,该方法仅关注基于时间的数据流特征,并利用支持向量机分类器在进行高效流量分类之前选择最佳特征子集 [16]。Anderson 等人将流元数据、包长度分布、时间分布、字节分布以及未加密的 TLS 头部信息作为联合特征,利用逻辑回归算法来识别恶意软件加密流量 [17]。Liu 等人设计了包级统计特征,利用发送和接收字节的最大值、最小值和平均值作为原始数据进行特征提取,并提出了一种基于复合特征的半监督方法用于加密流量分类 [18]。Zhang 等人提出了一种新的鲁棒流量分类 (RTC) 方案,该方案使用基于词袋 (BoF) 的流量分类器对数据流进行处理,并通过实验证明其性能显著优于最常见的机器学习方法 [19]。Fu 等人将加密流量流以分层方式分割成会话,并提取包长度和时间延迟序列来构建隐马尔可夫模型,该模型能够识别服务使用情况和终端用户的应用程序内行为 [21]。Fegghi 等人提出仅使用上行链路的数据包时序信息来测量 VPN 流量的方法,该方法无需了解网页请求的起始/结束时间,且不受数据包填充防御机制的影响 [22]。Panchenko 等人首次提出利用累计数据包大小特征生成 Tor 网站指纹,并被后续研究者广泛采用 [23]。

以上基于机器学习的方法都存在一个共性,其粒度都在流或会话级别,因为要获得通信模式并提取统计特征,需要观察整个流或会话,等待完整流结束才能进行决策,较高的时延使其无法满足实时分类的需求。同时,基于机器学习的方法都建立在特征工程的基础上,分类效果高度依赖专家的先验知识,且针对特定协议选取的特征往往缺乏通用性,在面对协议更新或流量分布偏移时,模型的鲁棒性较差。因此,基于机器学习的方法无法快速统一地选择的特征来分类加密流量,不适合流量类型和来源多变的真实网络场景。

1.2.3 基于深度学习的方法

受深度学习在图像处理和自然语言处理领域卓越性能的推动,研究人员将深度学习应用于网络流量分类。基于深度学习的方法不同于传统的基于机器学习的方法,其能够直接从原始字节流中提取高维非线性特征,有效克服了传统方法对专家经验的过度依赖。

早期的深度学习尝试多聚焦于将流量进行图像化,Wang 等人提出了一种用于加密流量分类的端到端方法,该方法将原始流量的字节数据作为输入,并将这些数据转换为灰度图像,再用一维 CNN 进行处理分类 [25]。Shapira 等人提出了一种用于加密互联网流量分类和应用识别的新方法 FlowPic,该方法将基本的流数据转换为直观的图像,然后使用卷积神经网络来识别流类别和正在使用的

应用程序 [27]。Liu 等人提出了一个通过深度神经网络进行加密流量分类的框架 FS-Net, 将数据包长度序列作为输入, 采用双向门控循环单元 (Bi-GRU) 进行特征编码, 并在自动编码器中结合了重构机制以保证学习到的特征的有效性 [26]。Liu 等人提出了一个名为 BGRUA 的模型, 用于识别在 HTTPS 连接上运行的 Web 服务。BGRUA 同样采用双向门控循环单元, 从会话内的字节序列中捕获前向和后向特征。此外, 还根据特征对分类任务的贡献程度为其分配不同权重 [28]。Lin 等人提出了一种新的流量表示模型, 称为加密流量双向 Transformer 编码器表示 (ET-BERT)。该模型利用大规模未标记数据进行预训练, 并根据两项预训练任务提取具有强力上下文联系的数据报级表示。第一项任务是通过预测被遮蔽的令牌来捕获流量字节间的上下文关系。第二项任务则是通过预测同源突发流来预测正确的传输顺序 [29]。Mohammad 等人提出了一种基于深度学习的加密流量分类方法 Deep Packet。该方法利用堆叠自动编码器和卷积神经网络进行应用识别任务 [30]。Aceto 等人提出了一种名为 MIMETIC 的多模态深度学习方法。他们分别利用 CNN 和 GRU 来学习两种不同的模态的特征, 即有效载荷的前 576 个字节和信息性协议字段, 并将其用于移动加密流量分类 [31]。Wang 等人也提出了一个类似的模型 App-Net, 该模型使用 LSTM 和 CNN 分别学习数据包长度序列和初始数据包的有效载荷字节数据, 分别提取特征 [32]。图神经网络 (GNN) 在处理非结构化数据方面具有强大潜力, 并在许多领域展现出良好的性能。Shen 等人提出了 GraphDApp, 该模型能够使用 GNN 识别去中心化应用 (DApps) 的加密流量。他们基于数据包长度和数据包方向构建了加密流的流量交互图 (Traffic Interaction Graph, TIG), 并将 DApp 识别问题转化为图分类问题 [33]。Han 等人提出了双嵌入图神经网络 (DE-GNN), 分别用 one-hot 编码处理包头和载荷数据, 并设计 PackertCNN 提取包级别特征, 然后构建流量交互图 (TIG) 并使用图神经网络学习流级别特征, 最后用自适应特征融合将二者融合作为最终的模型训练特征用于训练分类 [34]。Yang 等人提出了一个利用双模态特征的 DM-HNN 模型, 该模型同时使用包长度序列作为流级别特征和数据包数据作为包级别特征, 并通过门控激活机制自适应调整特征权重将其融合作为最终用于分类的特征进行模型训练 [35]。

现有深度学习方案虽已取得显著成效, 但仍存在一定的局限性。首先, 多数研究仍局限于单一模态, 如仅关注包长度序列或仅关注有效载荷, 未能充分挖掘流级特征与包级特征之间的协同效应。而现有的多模态融合尝试多为简单的向量拼接, 没有考虑到特征之间的相互关系 [36]。此外, 基于包长度序列的方法往往忽略了复杂网络环境如抖动、丢包等对时序特征的干扰, 从而导致特征表达不充分。而使用包级别特征的方法依赖有效载荷数据的使用, 这在增强分类精度的同时, 不可避免地增加了隐私泄露风险。

1.3 研究内容

针对上述问题，本文提出了两项研究，首先针对加密流量特征表达不充分、鲁棒性缺失等问题，本文研究并提出了一种基于自监督学习框架 BYOL 的流级别特征分类方法，该方法立足于流级别特征数据，通过构造抗干扰的特征提取模型，捕捉在网络波动影响下仍然不变的流级别鲁棒性特征，完成在复杂网络环境下也能顺利分类的任务。接着在获取高性能流级别特征的基础上，本文针对隐私保护不足、特征维度单一以及单一模态特征存在的类别混淆问题，进一步研究并提出了一种基于融合特征的加密流量分类方法，通过提取数据包内容构造包级别特征，并将两个模态的特征进行融合，从而构建具备高分类性能与强鲁棒性的表示特征，进一步增强了加密流量分类模型的有效性。通过上述两个阶段的研究，本文构建了从底层特征自动化表征到多维度特征深度融合的模型架构。具体研究框架如图 1.2 所示，主要研究内容涵盖以下三个方面：




图 1.2 研究内容结构图

(1) 面向网络环境波动的流级别鲁棒特征提取。针对网络拥塞、路径抖动及分片机制导致的流量时序特征失真问题，本文研究如何构建具备抗干扰能力的流级别特征表征模型。针对不同网络状态下的统计特性与时序规律提出不同的增强技术，并利用自监督对比学习机制捕捉流量中不随环境波动的不变性特征，缓解网络波动因素对分类模型泛效化能力的影响，提升模型在真实复杂场景下的分类可靠性。

(2) 兼顾表征能力与隐私保护的包级别特征提取。针对传统方法在处理包级别特征时，因过度依赖应用层有效载荷而带来的隐私安全与合规性问题，本文探

索了一种仅基于报文首部信息的特征提取策略。研究重点在于如何在完全规避敏感负载数据的前提下，通过对 IP 报文首部中协议号、标志位及窗口大小等结构化的关键字信息进行提取，并采取 n-gram 嵌入处理，捕捉数据报头的字节结构信息、文本顺序信息以及其与特定业务类型之间的隐式关联，从而在确保用户隐私合规性的同时，维持高水平的特征表示。

(3) 基于自适应注意力机制的双模态特征融合机制。针对单一模态特征表达能力受限以及传统融合策略，如简单拼接、静态加权难以有效处理特征间非线性关系的问题，本文研究并构建了一种基于注意力机制动态分配权重的双模态特征融合框架。通过引入注意力机制，模型能够根据流级别与包级别特征在不同业务场景下的贡献度差异，自适应地调整各模态特征在融合过程中的融合比例，从而充分利用双模态的互补信息，实现更深层次的特征语义对齐。

1.4 章节安排

本文主要包括五章，各章节主要内容的总结如下：

第一章为绪论。首先详细阐述了在网络空间安全日益严峻及加密流量普及的背景下，开展加密流量分类研究的重要现实意义与应用价值。接着，对国内外在该领域的研究现状进行了系统综述，对比分析了基于端口检测、深度包检测、传统机器学习以及现有深度学习方法的优缺点，指出当前研究在流级与包级特征融合、特征表示不足及隐私保护等方面存在的局限。在此基础上明确了本文的研究目标，并概括了论文在提升特征鲁棒性、强化隐私保护及构建动态融合框架等方面的三个主要研究内容，最后给出了全文的组织架构。

第二章为相关理论概述。本章为后续研究构建了必要的理论支撑体系，首先回顾了网络流量分类的基础理论，深入剖析了端口检测、DPI 及传统机器学习方法的内在机制与性能瓶颈。随后，重点探讨了深度学习的核心架构，详细介绍了卷积神经网络的层级结构、各类非线性激活函数与损失函数的作用机理，以及残差网络解决退化问题的优势。此外，本章还详细阐述了注意力机制在特征增强中的应用，以及自监督学习特别是对比学习在无标签数据表征学习中的前沿理论，为后文模型的设计奠定了坚实的数学与算法基础。

第三章为基于 BYOL 模型的流级特征分类方法。针对网络环境波动，如拥塞、抖动、分片等导致流量包长度序列失真的难题，本章提出了一种基于自监督对比学习的流级别鲁棒特征提取模型。通过引入 BYOL 框架，并设计了专门针对流量时序数据的增强函数，使得模型能够在无需负样本的情况下，通过在线网络与目标网络的相互映射学习，捕捉流量中不随环境变化的一致性表示。本章详细介绍了该模型的网络架构、编码器、投影器与预测器设计，并通过多组对比实

验验证了该方法在提升流级别特征稳定性及分类精度方面的卓越表现。

第四章为基于双模态融合特征的加密流量分类研究。在流级特征基础上，为解决单一维度特征表达能力不足导致的类别混淆问题，本章进一步探索了隐私保护导向的包级别特征提取策略，仅利用报文首部结构化信息作为原始输入，并通过 **n-gram** 嵌入捕捉字节之间的结构信息与顺序信息。此外还构建了一个基于自适应注意力机制的双模态融合框架，利用跨模态注意力机制动态量化流级别时序特征与包级别结构特征在不同业务场景下的贡献度，实现了特征间的深度语义对齐与非线性映射融合。实验结果表明，该融合模型在处理高度混淆的加密流量时，其准确率与可靠性均优于单一模态或简单拼接的分类方法。

第五章为总结与展望。本章首先对全文的研究工作进行了系统性总结，回顾了从自监督表征学习到多模态特征融合的完整加密流量分类体系的构建过程，并再次强调了本文在提升特征鲁棒性与隐私合规性方面取得的研究成果。随后，客观分析了当前模型在应对超大规模网络环境及异构网络自适应能力方面的局限性。最后，针对网络环境的动态化与智能化趋势，提出了未来研究的几个重要方向，包括加强跨域迁移学习能力、优化模型推理效率以及探索更精细化的流量行为建模技术。

第2章 相关理论概述

2.1 网络流量分类理论

随着第五代移动通信（5G）技术的广泛应用与万物互联进程的加速，现代网络环境正呈现出高带宽、低延迟及拓扑关系极端复杂的特征。这种演进在提升社会生产效率的同时，也导致网络安全威胁日益增多，恶意攻击的隐蔽性与多样化对现有的防护体系提出了严峻挑战 [27,28]。在此背景下，网络流量分类技术作为识别网络行为、保障服务质量及优化资源分配的核心手段，在入侵检测、流量计费及精细化网络管理领域发挥着不可替代的作用 [29-31]。从技术流程上看，网络流量分类通常包含数据采集、特征表示以及模型推断三个步骤 [32,33]。首先通过特定的网络工具捕获链路中的原始数据报文，随后利用特定的特征表征方法提取出能够刻画业务属性的关键信息，最后通过预定义的规则或训练好的模型实现类别的判定。针对网络流量分类问题，目前已经探索出了许多方法。

2.1.1 端口检测

基于端口号的识别方法是网络流量分类领域最基础且应用最早的技术手段，其核心逻辑依赖于互联网号码分配局所定义的公共端口与应用协议之间的固定映射关系。通过解析传输层首部中的源端口与目的端口信息，系统能够直接检索已知的协议数据库，从而快速判定流量所属的应用类型或服务性质。部分软件通常会使用特定的端口进行通信。因此，通过对网络流量中的端口号进行识别，可以初步筛选出特定软件的流量 [34]。在实际执行过程中，基于端口检测的方法主要包含四个步骤，数据采集、预处理、特征提取和分类识别。该方法首先利用网络监控工具或镜像技术获取原始数据，并在经过初步的去重与格式标准化等预处理操作对流量数据进行清洗和整理后，提取出报文头部的端口字段及通信频率、报文大小、通信时长以及特定的协议字段或行为模式等辅助特征，最终构建特征向量，最后基于提取的特征向量对网络流量进行分类。然而，随着网络环境的复杂化，该技术的局限性愈发凸显，现代互联网应用为穿透防火墙或增强通信隐蔽性，频繁采用动态端口或随机端口技术，且加密隧道技术的广泛使用使得端口号不再具有唯一代表性，导致该方法的查全率与准确率大幅度下降。

2.1.2 深度包检测

为了弥补端口识别在处理动态协议时的不足，基于有效载荷分析的深度包检测技术应运而生，其原理在于通过对数据包的应用层内容进行深度解析以获

取业务特征 [8]。

DPI 技术的核心在于构建一个庞大的应用层特征签名数据库，通过将待检测报文的有效载荷内容与数据库中存储的关键字段或特定序列进行逐字节的比对，实现对流量属性的精准定位。相比于传统的端口匹配，DPI 分析的是数据包中的有效载荷，因此能够识别如诸如 P2P 等使用随机端口进行数据传输的应用程序。Sen 等人通过提取 P2P 协议特有的握手签名，实现了对复杂对等网络流量的高效跟踪 [9]。尽管 DPI 在识别精度上具有显著优势，但其弊端也同样明显：一方面，深度解析载荷需要消耗大量的计算资源与内存带宽，对于大规模网络流量的处理可能带来挑战，同时也难以满足网络流量分类的实时性要求。另一方面，随着各种加密技术和协议的普及，报文有效载荷呈现高度随机化，导致 DPI 无法在不解密的情况下提取有效特征，其在加密流量环境下的有效性受到了极大限制。并且，对于不在特征库中新型的应用协议，DPI 无法对其在已有的数据库中进行匹配，从而不能做到准确的分类和识别。

2.1.3 传统机器学习方法

基于传统机器学习的网络流量分类方法倾向于利用流量在传输过程中展现出的统计行为模式而非载荷内容进行特征表征，这些统计特征通常包括数据包的大小分布、到达时间间隔、会话持续时长以及协议交互频率等。通过对这些高维特征的提取与分析，机器学习模型能够捕捉到不同业务类型在宏观行为上的本质差异 [37]。由于该类方法无需对报文载荷进行逐包解析，因此在处理效率上远高于 DPI 技术，且天然具备识别加密流量的能力。然而，传统机器学习方法的性能高度依赖于人工特征工程的质量，这要求研究者必须具备深厚的领域背景知识以筛选出最具区分度的特征子集。并且数据流的统计特征提取通常以数据流或会话为基本粒度，处理过程往往需要捕获完整的数据流，这也为流量的分类效率造成了一定的瓶颈。同时，面对不断涌现的新型网络应用，此类方法往往需要大量的标注样本进行反复训练与模型优化，在特征表达的灵活性与复杂非线性关系的建模能力上，仍存在一定的优化空间。

2.1.4 基于深度学习的方法

基于深度学习的网络流量分类方法通过构建多层次非线性的深度神经网络架构，实现了特征提取与分类决策的有机统一，彻底改变了依赖人工干预的传统范式。在深度学习端到端的学习框架下，模型能够直接以原始报文数据作为输入，在训练过程中自动挖掘并学习数据中具有强区分度的特征表征。这种机制不仅能够有效捕获原始网络数据与复杂分类目标之间的高维非线性关联，还显著提升了模型在面对未知协议或流量扰动时的鲁棒性。因此，本文将对深度学习做

系统性的概述，并基于深度学习技术开展网络加密流量分类的研究工作。

2.2 深度学习概述

作为机器学习领域的核心分支，深度学习的本质在于通过构建多层次的神经网络架构，实现从原始数据到高阶抽象特征的自动归纳与学习 [55]。相较于传统机器学习高度依赖人工特征工程的局限性，深度学习通过端到端的学习机制实现了特征提取过程的自动化与智能化。近年来，得益于计算算力的显著提升以及算法架构的持续优化，深度学习技术经历了跨越式发展，已成为处理复杂模式识别与生成任务的关键技术路径。

深度学习的理论基石在于深度神经网络，其通过多层感知机或更深层级的神经元连接结构，模拟人类大脑的信息处理与传递机制。在典型的模型拓扑结构中，深度学习架构由输入层、多个隐藏层以及输出层协同组成。其中，隐藏层通过引入非线性激活函数，承担了特征非线性映射、维度变换与表征增强的核心职能。在模型训练阶段，该技术主要采用反向传播算法进行参数更新，通过梯度下降等优化策略持续最小化损失函数值 [56]。深度学习的优势不仅体现在其卓越的非线性表达能力与架构灵活性上，更在于其应对海量多源数据及高维特征空间时的稳健表现。目前，深度学习领域已衍生出多种针对特定任务优化的模型变体，例如擅长空间特征捕获的卷积神经网络、适用于序列建模的递归神经网络以及具备强大生成能力的生成对抗网络等 [57-59]。这些演进架构在自然语言处理、语音识别、时间序列分析及自动驾驶等尖端领域均展现出了卓越的性能表现 [60-63]。随着计算技术的演进与数据规模的指数级增长，深度学习在深度特征表征、复杂模式识别及大规模任务建模等方面，依然蕴含着广阔的研究价值与应用前景 [64]。

2.2.1 卷积神经网络

卷积神经网络是深度学习领域中最具代表性且应用最广泛的模型架构之一。其设计灵感源于生物视觉皮层对外界事物的感知机制。相较于传统的全连接神经网络，CNN 凭借其卓越的局部特征捕获能力与层次化表征学习机制，在计算机视觉、自然语言处理以及网络安全流量分析等领域展现出了极强的鲁棒性与泛化性能。CNN 的典型拓扑结构是一个多级联动的非线性映射系统，主要由输入层、卷积层、池化层、全连接层以及输出层协同构成，其标准逻辑架构如图 2.1 所示。通过这些异构层级的交替堆叠，网络能够实现从底层几何纹理到高层语义属性的逐层抽象与演进。各组成部分的具体介绍如下：

1) 卷积层




图 2.1 卷积神经网络结构

卷积层是 CNN 的核心组件，主要承担从输入数据中捕获局部空间特征的功能。设输入特征图的维度为 $W \times H \times C$ ，其中 W 和 H 分别代表特征图的宽度与高度， C 代表输入通道数，即特征图的总数。卷积层通过应用一组可学习的卷积核与输入数据进行互相关运算。卷积核的数量直接决定了输出特征图的通道深度，每个卷积核通过在空间维度上滑动，提取特定的模式特征并生成相应的特征映射。

卷积操作的输出受一系列超参数驱动，主要包括输入数据尺寸 i 、卷积核尺寸 k 、步长 s 、填充大小 p 以及输出尺寸 n 。其中，步长 s 决定了特征提取的分辨率精细度；填充 p 则常用于保持特征图的空间维度，防止由于深层堆叠导致的边缘信息坍塌。输出特征图的维度 n 可通过公式 $n = (i - k + 2p)/s + 1$ 计算。卷积层之所以在处理大规模高维数据时表现优异，主要归功于其核心的参数共享与局部连接两大特性。这两大特性极大地缩减了待训练参数的规模，在维持模型表达能力的同时，显著降低了计算复杂度。不同尺寸的卷积核可提取多尺度的特征，并赋予模型对输入信号在平移、旋转及缩放等变换下的不变性。以二维卷积为例，如图 2.2 所示，假设输入为 4×4 的数据矩阵，采用 3×3 的卷积核且步长 $s = 1$ 对其进行处理。在运算过程中，卷积核逐像素移动并执行元素级乘加运算，最终将原始冗余信息压缩并映射为一个 2×2 的输出矩阵，实现了特征的初步抽象。

2) 池化层

池化层，又称下采样层，通常嵌入在连续的卷积层之间，其核心使命在于通过降维手段实现空间抽象化。引入池化层主要基于三个核心目的，首先，通过减少特征图的空间分辨率，显著降低后续网络层的计算负担与内存占用；其次，通过聚合局部区域的信息，池化层能够有效缓解模型对输入微小位移或噪声的敏感性，从而增强模型的空间不变性；最后，这种降采样机制具有自然的正则化效




图 2.2 卷积运算过程

应，能够在一定程度上抑制过拟合现象。

在工程实践中，最大池化（Max Pooling, MP）与平均池化（Average Pooling, AP）是最具代表性的两种策略。如图 2.3 所示，最大池化旨在从邻域窗口中筛选出响应值最强的特征信号，如提取图像中最明显的边缘或流量中最显著的突发特征，这种方式更有利于保留纹理信息；而平均池化则计算窗口内所有元素的期望值，倾向于平滑特征并保留背景的统计学特性。以图 2.3 为例，对于 4×4 的输入矩阵，若采用 2×2 的池化核且设置步长 $s = 2$ ，最大池化将提取窗口内的峰值，而平均池化则输出均值。这种通过牺牲空间分辨率来换取特征高级性的策略，是 CNN 能够处理复杂结构化数据的关键。在实际应用中，最大池化和平均池化有不同的应用场景，需要根据不同的情况选择合适的池化操作，才能达到最优的模型性能表现。

3) 全连接层

全连接层通常部署在 CNN 架构的末端，扮演着全局信息整合器的角色。与前述层级不同，全连接层中的每一个神经元均与前一层的所有输出节点存在全权值连接，这种稠密的连接方式使其能够突破局部感受野的限制，具备全局视野。该层的运作过程可分为特征重组与空间映射两个阶段，在特征重组阶段，网络将前层提取到的分布式、局部的多维特征张量进行展平处理，转化为一维特征向量；在空间映射阶段，通过与权重矩阵的线性组合，全连接层将这些高度抽




图 2.3 两种池化方式

象的特征投影到最终的样本标记空间。其数学表达通常为 $y = \sigma(Wx + b)$ ，其中 σ 为激活函数。全连接层的深度与宽度决定了模型的最终判别能力，通过对连接权值的迭代优化，网络能够学习到不同特征之间的复杂非线性组合逻辑。这一设计确保了模型能从局部的特征感知过渡到全局的语义理解，为下游的分类、回归或识别任务提供最终的决策依据。

2.2.2 激活函数

深度学习的核心机理构建在人工神经网络的基础之上。在多层神经元结构的传递过程中，每一层神经元接收来自前一层输出的加权总和，并据此生成自身的响应信号传递至下一层。在这种层级化的构造中，上层节点的输出与下层节点的输入之间并非简单的线性叠加，而是通过一个关键的数学算子进行转换，该算子即为激活函数。作为神经网络实现非线性变换的核心要素，激活函数在模型整体表征能力的构建中发挥着不可替代的作用。从数学本质上看，若神经网络仅由线性算子堆叠而成，由于线性变换的复合性，无论网络层数如何增加，其最终输出依然只能表示为输入的线性组合。这种架构在本质上等价于单层感知机，其性质受限于线性模型的范畴，无法有效拟合高维空间中复杂的非线性映射关系，极大地制约了模型的逼近能力。通过在各层之间反复引入非线性激活函数，神经网络能够打破线性约束，实现对数据中高阶语义信息的捕捉与提取，从而赋予深层网络卓越的特征表征与模式识别能力。

激活函数的选择直接关系到深度学习模型的收敛速度、泛化性能及训练稳

定性，一直是学术界研究的核心议题。随着算法架构的演进，激活函数的种类日趋丰富，为针对特定任务优化模型提供了广阔的选择空间。图 2.4 展示了当前主流激活函数的几何图像，表 2.1 则对其数学表达式进行了详细汇总。




图 2.4 常见的激活函数图像

常见的激活函数类型	$f(x)$
Sigmoid	$\frac{1}{1 + e^{-x}}$
Tanh	$\frac{1 - e^{-2x}}{1 + e^{-2x}}$
ReLU	$\max(0, x)$
Leaky ReLU	$\max(0.01x, x)$
ELU	$\begin{cases} \alpha(e^x - 1), & x \leq 0 \\ x, & x > 0 \end{cases}$
PReLU	$\begin{cases} \alpha x, & x < 0 \\ x, & x \geq 0 \end{cases}$

表 2.1 常见激活函数的公式

1) Sigmoid 函数

Sigmoid 函数是一类经典的 S 型非线性激活函数，其数学形态与生物神经元的激活特性高度契合。在早期神经网络研究中，Sigmoid 被广泛用作阈值函数，

能够将输入变量平滑地映射至 $[0, 1]$ 区间内，常用于二分类任务的概率输出。然而，Sigmoid 函数存在显著的梯度消失问题。由于该函数具有双侧软饱和性，当输入值的绝对值较大时，其梯度趋近于零。在深层网络的反向传播过程中，层层累积的梯度乘积会呈指数级衰减，导致底层参数更新停滞，模型难以完成收敛，即出现梯度消失问题。

2) Tanh 函数

Tanh 函数作为双曲正切函数，在形态上与 Sigmoid 相似，但其值域扩展至 $(-1, 1)$ 。相较于 Sigmoid，Tanh 的显著优势在于其输出分布是零中心化的，即输出均值接近于 0。这一特性在一定程度上加速了神经网络的收敛过程。尽管 Tanh 在梯度表现上优于 Sigmoid，但其在输入值过大或过小时依然无法摆脱软饱和性带来的梯度消失困境，因此在极深层网络中的应用仍受到限制。

3) ReLU 函数及其变体

为了克服饱和激活函数的局限性，修正线性单元 (Rectified Linear Unit, ReLU) 应运而生，并逐渐成为深度学习领域的主流选择。ReLU 函数通过简单的截断机制选取 x 与 0 的最大值，使得正半轴的导数恒为 1。这种设计不仅极大地简化了梯度计算量，显著提升了随机梯度下降的收敛速度，并从根本上缓解了正向区域的梯度消失问题。然而，原生 ReLU 存在神经元死亡的风险。当输入为负值时，激活输出与梯度均为零，导致相关神经元在训练过程中可能进入不可逆的失活状态。为此，学术界提出了一系列 ReLU 变体，形成了 ReLU 函数簇。

首先是 Leaky ReLU 函数，通过为负值区域引入一个极小的固定斜率，保留了负半轴的信息流，有效预防了神经元失活问题。其次是 ELU (Exponential Linear Units) 函数，融合了 Sigmoid 的软饱和性与 ReLU 的线性优点。其在负半轴的指数衰减特性增强了模型对输入噪声的鲁棒性，同时均值更接近零的输出有助于进一步加快训练收敛。此外还有 PReLU (Parametric ReLU) 函数，通过将负值部分的斜率设为可学习参数 α ，使其能够随训练过程动态调整。这种设计赋予了模型更高的灵活性，使其能根据数据集特征自主学习最适宜的激活特性。

综上所述，激活函数的设计正朝着更具灵活性、更强梯度稳定性以及更优数值分布的方向演进。在具体工程应用中，需根据网络深度、数据分布以及计算资源等因素，选择最为匹配的激活算子，以实现模型性能的最优化。

2.2.3 损失函数

在深度学习的参数优化过程中，损失函数是衡量模型预测输出与真实标签之间差异程度的核心测度工具。其本质上构建了一个从参数空间到标量误差空间的映射，为神经网络的训练提供了一个可量化的优化目标。借助于反向传播算法，损失函数产生的误差信号能够通过计算偏导数转化为梯度流，进而引导优化

器对网络权值进行迭代更新。损失函数的选择不仅决定了神经网络的收敛方向与演进速率，更深刻影响了模型最终在未知数据上的泛化性能。在不同的学习任务中，损失函数的构造逻辑各具特色。通常而言，回归任务侧重于度量数值间的欧几里得距离，而分类任务则侧重于评估概率分布之间的相似性。在深度学习领域，最具代表性的损失函数包括均方误差（Mean-square Error, MSE）、平均绝对误差（Mean Absolute Error, MAE）、交叉熵（Cross Entropy, CE）以及 KL 散度（Kullback-Leibler Divergence, KL）。为了严谨表述各函数的数学机理，假设样本的真实标签值为 y_i ，模型的预测输出值为 p_i ，样本总数或总类别数为 N 。各典型损失函数的定义及数学公式如表 2.2 所示。

常见的损失函数	公式
MSE 损失函数	$\frac{1}{N} \sum_{i=1}^N (y_i - p_i)^2$
MAE 损失函数	$\frac{1}{N} \sum_{i=1}^N y_i - p_i $
CE 损失函数	$-\sum_{i=1}^N y_i \log(p_i)$
KL 损失函数	$\sum_{i=1}^N y_i \log \frac{y_i}{p_i}$

表 2.2 常见损失函数的公式

1) 均方误差与平均绝对误差均方误差

均方误差通过计算预测值与真实值差值的平方和来衡量误差。由于其平方项的存在，MSE 对离群点具有较高的敏感性，能够显著放大较大误差对梯度的贡献，从而迫使模型快速向减小大幅误差的方向收敛。相比之下，平均绝对误差则采用一阶绝对差值，其梯度在整个定义域内更为稳定，在处理含有较多噪声或异常值的数据集时表现出更强的鲁棒性。

2) 交叉熵损失函数

交叉熵是当前多分类及二分类任务中的主流损失函数。从信息论角度来看，交叉熵衡量了预测概率分布与真实分布之间的信息差异。相较于分类任务中的 MSE，交叉熵在激活函数进入饱和区时，依然能够提供较强的梯度信号，从而有效规避了训练初期的学习缓慢问题。在诸如加密流量协议识别或恶意样本检测等任务中，交叉熵能够迫使模型在正确类别上产生更高的置信度。

3) KL 散度

KL 散度又称为相对熵，主要用于评估两个概率分布 P 和 Q 之间的不对称差异。在自监督学习、生成对抗网络或变分自编码器中，KL 散度常被用于约束隐含变量的分布形态，使其趋向于先验分布。它是衡量模型学习到的分布与目标分布重合程度的关键指标。

2.2.4 残差神经网络

残差神经网络作为卷积神经网络演进过程中的一项变革性创新，凭借其卓越的特征表征能力与深层架构稳定性，在图像分类、目标检测及语义分割等计算机视觉任务中展现出了超越传统的性能表现。ResNet 的核心贡献在于系统性地揭示并剖析了深层神经网络中普遍存在的退化问题。在传统的深度学习视角下，学术界普遍认为增加网络的深度能够有效地提升模型的非线性表达能力与特征抽象层次。然而，真实情况却是，当网络深度超越某一临界阈值后，模型的训练准确率与测试准确率均会出现非预期的饱和甚至下降现象。需明确的是，这种退化现象并非由过拟合导致，因为退化同时表现在训练集上，其本质源于深层架构带来的优化困境，即随着层数的叠加，反向传播过程中的梯度流会因连乘效应而产生剧烈的消失或爆炸，导致底层参数更新失效，使得模型难以收敛至全局最优状态。

为化解深层网络的优化难题，ResNet 引入了创新的跳跃连接机制，并以此构建了残差块作为网络的基本构建单元。在残差块的设计中，输入特征 x 不仅参与常规的卷积变换，还通过一条恒等映射路径直接跨层传递至后续层，与经过多层卷积、批归一化及非线性激活处理后的残差映射 $F(x)$ 进行逐元素相加。其数学表述为： $H(x) = F(x) + x$ 。其中， $H(x)$ 为该单元的最终输出。这一设计在数学逻辑上将原本复杂的非线性映射拟合任务转化为对残差函数 $F(x) = H(x) - x$ 的优化。当网络层趋于冗余时，跳跃连接能够强迫残差部分趋近于零，从而使该层退化为恒等映射，确保了深层网络至少不会弱于浅层网络的表现。而在反向传播方面，残差结构在反向传播过程中构建了一条梯度高速公路，使得损失函数的梯度能够绕过复杂的非线性层，直接回传至浅层参数。这种机制极大地缓解了梯度消失问题，确保了网络在扩展至数百甚至上千层深度时，依然能够保持稳定的训练动态与高效的特征学习效率。

ResNet 的提出不仅在理论层面深化了对深层神经网络训练机制的科学认知，更在实践层面打破了神经网络深度的物理限制，使得构建超深层架构成为可能。此外，残差学习已不局限于计算机视觉领域，而是被广泛应用于自然语言处理、语音识别及强化学习等多元化场景，对推动整个深度学习领域的进步产生了极其深远的影响。

2.2.5 注意力机制

注意力机制作为当代深度学习架构中的核心建模范式，其本质是一种资源分配方案。该机制的研究可追溯至早期的序列建模任务，最初旨在解决循环神经网络在处理长序列时由于梯度消失或梯度爆炸而导致的长程记忆缺失难题。随着深度学习理论的纵深演进，注意力机制在信息筛选、特征增强及全局关联建模方面展现出了独特的逻辑优势，已成为提升模型表征能力与泛化性能的关键技术。注意力机制的核心思想源于人类视觉与感知系统的选择性注意原理。在面对海量且复杂的外部信息输入时，人类大脑并不会对所有信息进行等权重的处理，而是会通过快速扫描全局，将有限的认知资源集中于关键的目标区域，同时忽略或弱化无关背景信息的干扰。这种机制不仅极大地提升了人类处理信息的效率，也为人工神经网络的设计提供了重要参考。在数学层面，注意力机制赋予了模型自主学习并分配特征权重的能力，通过计算输入向量之间的相关性，模型能够动态地增强关键特征的表达强度，并抑制冗余信息的负面影响，从而在有限的计算资源下实现对复杂映射关系的高效捕捉。

自 Bahdanau 等人首次将注意力机制引入神经机器翻译任务以来，该技术迅速引发了学术界的广泛关注 [66]。通过打破固定长度编码向量的瓶颈，注意力机制使得模型能够根据解码需求动态地回顾源序列中的特定部分。Vaswani 等人提出的 Transformer 架构更是将这一理论推向了新高度 [67]。该架构通过自注意力机制彻底取代了传统的循环结构，实现了高度的并行化计算与对长程依赖关系的有效建模。多头注意力机制的引入，允许模型在多个独立的特征子空间中并行学习互补的关联信息，显著提升了模型在处理大规模复杂任务时的性能上限与训练收敛效率。依据应用场景、计算维度及拓扑架构的差异，注意力机制在实际工程应用中可细分为若干主流类型。自注意力机制：侧重于挖掘序列内部元素间的相互演化逻辑，通过计算序列自身项与项之间的关联权重，实现上下文感知的特征重构。多头注意力机制：通过多组线性变换将特征投影至不同的子空间，并在各空间内独立执行注意力运算，旨在捕获多尺度的特征关联。空间与通道注意力机制：广泛应用于计算机视觉领域，分别通过在空间维度定位关键区域以及在通道维度筛选关键特征，实现对卷积特征图的精准校准。

如图 2.5 所示，注意力机制的处理过程通常涉及查询向量（Query）、键向量（Key）与值向量（Value）三者的交互运算。通过缩放点积或其他度量函数计算 Query 与 Key 的相似度，经过 Softmax 归一化后获得权重分布，最后对 Value 进行加权求和，从而输出兼具全局视野与局部焦点的特征表征。这种高度灵活且具备物理解释性的机制，已成为推动自然语言处理、计算机视觉以及跨模态学习等前沿领域进步的核心驱动力 [68]。




图 2.5 注意力机制处理过程

2.3 自监督学习

自监督学习作为无监督学习范式中的重要分支，其核心价值在于缓解深度学习模型对大规模高质量标注数据的过度依赖。在无法获取人工标注标签的实际应用场景下，自监督学习通过挖掘未标注数据自身的内在结构、时空关联或统计特征，构建具有挑战性的辅助任务。这种机制能够利用数据自身生成的伪标签作为监督信号，驱动模型在解决辅助任务的过程中自动习得具有高度泛化性的特征表征，从而将样本固有的属性转化为模型训练的有效约束，显著增强了神经网络在下游任务中的特征提取效能 [59]。从技术演进路径来看，自监督学习主要涵盖生成式方法与对比式学习方法两大类 [60]。生成式方法通常依托于自编码器、变分自编码器或生成对抗网络等架构，其优化目标侧重于对原始输入数据的像素级或元素级重构。相比之下，对比式学习作为近年来该领域的主流演进方向，不再追求数据的精确恢复，而是侧重于在潜在特征空间中构建判别性准则，通过评估样本间的相似性差异来学习深层语义表征。这种范式表现出更低的任务复杂性与更优的计算效率，已广泛应用于计算机视觉、自然语言处理等前沿领域。在网络安全流量分析中，相关研究亦证明了自监督学习具有极强的指纹提取能力，能够有效应对加密环境下特征稀疏与标签匮乏的挑战 [61][54]。

2.3.1 对比学习

对比学习作为一种主流的自监督学习范式，其核心机理在于通过代理任务的设计与目标函数的构造，在嵌入空间中实现对样本关联性的深度建模。其优化逻辑与传统有监督学习直接依赖离散标签指导优化存在本质区别 [62]。对比学习通过巧妙定义的正负样本对，将特征学习转化为一个判别性任务，并通过一个

特定的目标函数量化正负样本对之间的损失差异，从而指导模型优化 [63]。该过程首先利用不同的数据增强算法，对原始样本进行多视图转换，进而产生两个源自同一锚点样本的正样本对 x_i 和 x_j ；随后，这些视图经由共享参数的深度编码器 f 映射至高维潜在特征空间，得到特征向量 h_i 和 h_j 。接着进一步通过非线性投影头 g 进行变换，得到最终的对比向量 z_i 和 z_j 。对比学习的最终优化目标是实现在特征空间内，尽可能缩小同一原始样本不同增强视图之间的度量距离，同时最大化不同原始样本视图之间的距离。在最终阶段，通过引入对比损失函数，模型能够学习到对噪声鲁棒且具备类别区分度的特征表征。这种类比式的学习逻辑使得模型在无须外部标签的情况下，能够自发地捕捉到数据的核心特质，从而显著提升模型在各类下游识别任务中的泛化能力与表示效率。具体的处理过程如图 2.6 所示。




图 2.6 对比学习过程

2.3.2 数据增强

数据增强技术是对比学习得以成功实施的理论基石，其本质是通过向模型引入特定的先验知识，诱导其在训练过程中学习到对各类扰动具备不变性的核心特征。在计算机视觉领域，数据增强已形成了一套包含几何变换、色彩扰动、噪声注入及结构化遮挡的系统性策略体系 [65]。例如，通过旋转、缩放与随机剪裁等几何变换，可以强迫模型忽略空间位置的偏差而专注于目标的拓扑结构；而色彩抖动与模糊算子则能增强模型对环境光影及传感器噪声的容忍度。在对比

学习框架下，数据增强的作用并非简单的样本扩充，而是在定义模型应当对哪些属性保持语义不变性。通过将不同的增强策略进行异构组合，模型能够识别出跨视图的共性语义特征，有效防止了模型对单一局部特征的过度依赖或过拟合。Chen 等人的研究证明不同的数据增强策略对于模型效果的提升存在显著差异 [64]。多样化的增强策略组合对于表征能力的提升具有显著的协同效应。因此，针对特定数据域设计具有针对性的数据增强策略，是构建高效对比学习模型、实现跨域泛化能力提升的关键环节。

2.4 本章小结

本章对网络流量分类理论、深度学习技术及其在特征提取与表征学习中的应用进行了全面系统的梳理，为后续研究基于深度学习的加密流量分类方法奠定了坚实的理论基础。首先，本章回顾了网络流量分类的发展历程，详细分析了传统的端口检测技术、深度包检测技术、基于传统机器学习方法和基于深度学习方法的基本原理。虽然 DPI 在识别精确度上具有优势，但在面对日益普及的加密流量时显得力不从心；而基于传统机器学习的方法虽能处理加密流量，却高度依赖人工特征工程的质量。

随后，本章深入介绍了深度学习的核心原理及关键组件。我们重点介绍了卷积神经网络在局部特征提取方面的卓越能力，并解释了残差神经网络如何通过跳跃连接机制有效缓解深层网络中的梯度消失与退化问题，从而支持更深层次的特征挖掘。同时，本章还论述了激活函数、损失函数以及注意力机制在优化模型表达能力和信息筛选方面的关键作用，特别强调了注意力机制在建立全局特征关联与增强关键信息方面的独特优势。

最后，针对无标签数据的高效利用问题，本章介绍了自监督学习及对比学习的基础理论。通过对对比学习原理和数据增强模块的详细论述，我们阐明了模型如何在无需人工标注的情况下，通过构建正负样本对来学习更具区分度的特征表征。这一理论体系不仅为解决加密流量样本标注难题提供了思路，也为后文构建基于 BYOL 模型的分类方法提供了重要的理论支撑。

第3章 基于 BYOL 模型的流级特征分类方法

在本章中，我们将详细介绍本文所采用的基于自监督学习架构的流级特征分类模型。该模型核心基于非对称对比学习架构 BYOL，通过在流量数据上进行自编码学习，提取具有强鲁棒性的流级特征表示，再将模型提取后的特征用于下游分类任务。原版的 BYOL 模型处理对象为二维图像，我们对其编码器，增强函数进行了调整，使其能够满足网络流量类型数据的特征提取需求。模型通过使用差异化的增强，构造两种不同的数据包长度序列流量变体，并将同一流量的两个变体输入双网并行架构，进行适当的映射，使二者在高维空间中距离拉近，从而提取出经过增强变化后，两个变体之间共有的，具有鲁棒性的流级别特征。

3.1 系统模型

BYOL (Bootstrap Your Own Latent) 是一种基于自监督学习的图像表示学习方法，其核心思想是通过两个神经网络的协同训练实现特征学习，从而为下游任务学习一种高质量的表示方法。该方法的总体架构由两个具有对称结构但更新机制与参数相互独立的神经网络组成：在线网络 (Online Network) 与目标网络 (Target Network)。

在线网络是在线学习的主体，由一组权重 θ 定义，包含三个组成部分：编码器 (f_θ)、投影器 (g_θ) 和预测器 (q_θ)。它通过梯度下降法来优化参数，学习图像的特征表示。

目标网络在训练中充当在线网络的“导师”，其参数 ξ 由另一组权重定义，仅包含编码器 (f_ξ) 和投影器 (g_ξ) 两个组成部分。目标网络的参数 ξ 通过在线网络参数 θ 的指数移动平均值 (EMA) 进行更新。目标网络为在线网络提供稳定的回归目标，同时通过梯度停止机制避免直接参与梯度更新，这种设计使得目标网络能够逐步逼近在线网络的状态。

这种设计使得目标网络能够逐步逼近在线网络的状态，同时避免模型坍塌，从而提升表示学习的鲁棒性。如图 3.1。




图 3.1 BYOL 模型框架

3.2 增强函数

在 BYOL 模型中数据增强操作对于学习良好的数据表征起着至关重要的作用。首先，不同的数据增强操作引入不同的扰动，生成不同增强视角下的样本，模型从中捕捉数据的不变特征，使其在无需负样本的情况下实现高效的特征学习，从而为下游任务提供支持。因此，设计合理的增强函数对于提升模型的性能至关重要。

真实网络环境的复杂性体现在其多变性和不可预测性，尤其是面对网络拥塞、延迟以及带宽波动等问题。如图 3.2 所示，这些网络环境问题可能会导致出现丢包、数据包乱序、数据包重复等问题，拥塞常常会导致数据包丢失，因为路由器或交换机会因为缓存容量不足而被迫丢弃无法及时转发的数据包。其次，为了应对丢包现象，许多传输层协议会启动重传机制，即发送方在一定时间内未收到确认响应时，重新发送已发出的数据包，以保证数据的完整性。另外，原本有序发送的数据包在传输过程中可能因为不同路径的传输延迟差异而到达接收端的顺序发生改变，导致数据包的乱序。Xie 人 [61] 的研究表明目前基于 TCP 可靠传输的数据包长度序列的三个主要变化，即数据包序列移位、数据包序列重复和数据包大小变化。而基于 UDP 的传输方式则还可能出现数据包丢失的情况。通过设计合适的数据增强方式，模拟真实网络环境和加密技术对于流量的影响，可以让模型学习到隐含的本质规则和语义。针对流级别特征提取任务，我们设计了两种增强函数，分别为噪声注入和尺度缩放与特征遮蔽。这两种增强函数能够模拟网络流量数据中的常见变异情况，增强模型的鲁棒性和泛化能力。




图 3.2 数据包序列变化

3.2.1 增强函数 1：噪声注入

第一个增强函数为噪声注入。真实的物理网络中，由于 MTU 限制、中继设备重新分片、协议栈填充或 TCP 粘包拆包等原因，数据包长度并非一成不变，个别数据包可能因为网络条件的变化而出现长度波动。噪声能模拟这种不确定性。

通过向特征向量添加均值为 0、标准差为 0.05 的随机噪声，模型就能够模拟网络测量过程中产生的个别数据包长度变化现象，从而提升模型对网络环境扰动的鲁棒性，本文定义了基于高斯分布的加性噪声变换 $\mathcal{T}_{noise}$ 。对于输入的流级特征序列 $\mathbf{x} \in \mathbb{R}^L$ ，变换后的输出为：

$$\mathcal{T}_{noise}(\mathbf{x}) = \mathbf{x} + \boldsymbol{\eta}, \quad \boldsymbol{\eta} \sim \mathcal{N}(0, \sigma^2)$$

其中， $\sigma = 0.05$ ， $\mathbf{x} \in \mathbb{R}^L$ 为原始输入序列， $\boldsymbol{\eta}$ 为随机生成的噪声，服从均值为 0、标准差为 0.05 的正态分布。

3.2.2 增强函数 2：尺度缩放与随机遮蔽

第二个增强函数为尺度缩放与随机遮蔽。不同层级的隧道协议（如 VPN, TLS, IPv6 额外头部）会对原始载荷添加不同大小的头部，从而使得整个流的数据包长度均发生变化。尺度缩放能让模型学会忽略绝对大小，转而关注包与包之间的相对比例关系。为了模拟这一现象，定义尺度缩放变换 $\mathcal{T}_{scale}$ 为：

$$\mathcal{T}_{scale}(\mathbf{x}) = \alpha \cdot \mathbf{x}, \quad \alpha \sim \mathcal{U}(1 - \epsilon, 1 + \epsilon)$$

其中 α 是为每个样本独立生成的缩放因子，服从区间为 $[0.8, 1.2]$ 的均匀分布（即 $\epsilon = 0.2$ ）。

拥塞的网络环境可能会导致非可靠传输协议传输的数据流发生数据包丢失现象。随机遮蔽则可以模拟数据包在传输过程中丢失或被截断的场景，确保模型在信息不全的情况下依然能做出准确判断。定义掩码变换 $\mathcal{T}_{mask}$ 。首先构造一个二值掩码张量 $\mathbf{M} \in \{0, 1\}^L$ ：

$$\mathbf{M}_{i,j} = \begin{cases} 0, & \text{with probability } P_{mask} \\ 1, & \text{with probability } 1 - P_{mask} \end{cases}$$

随机遮蔽变换为：

$$\mathcal{T}_{mask}(\mathbf{x}) = \mathbf{x} \odot \mathbf{M}$$

其中， P_{mask} 是遮蔽概率，设定为 0.1。通过强制移除 10% 的特征信息，迫使在线网络学习利用剩余维度的关联性来重构整体表征，从而提高模型在数据包丢失环境下的判别能力。

通过级联尺度缩放与随机遮蔽，第二个增强函数构建了一个信息更加匮乏的目标视图，使得模型能够深入挖掘特征间的内在关联。

3.3 模型架构

3.3.1 编码器

在经过上述增强函数的处理后，模型获得了原始流量数据的两个不同增强变体 v 和 v' 。随后，这两个变体被分别输入在线网络和目标网络中的编码器 f_θ 和 f_ξ 进行特征表示。在原 BYOL 研究框架中，编码器架构以 ResNet[79] 为基础，用于获取二维图像的特征表示，输入通常是 (C, H, W) ，即（通道、高度、宽度）。而网络流量的数据包长度序列本质上属于一维结构化数据，传统的 ResNet 等图像骨干网并不适用。鉴于此，本文使用一维卷积神经网络作为骨干架构。1D-CNN 的卷积核在单个维度上滑动，这与流量序列按照时间轴线性排列的特征完全吻合，能够通过一维卷积算子在特征轴上有效地捕捉局部统计依赖性，同时避免了二维卷积在处理非图像数据时引入的维度冗余。

本工作设计的编码器采用了逐层特征升维的策略，将初始输入的数据包长度序列，经过多层卷积和池化操作后，最终输出一个 256 维的表征向量。如图 3.3 所示。输入向量为经过标准化的一维向量 $\mathbf{v} \in \mathbb{R}^{B \times 1 \times L}$ ，其中 B 为批处理大小， L




图 3.3 编码器结构

为数据包序列长度。首先，经过浅层特征提取层，使用 128 个大小为 3 的卷积核进行初步扫描，通过 BatchNorm1d 稳定分布并经过 ReLU 进行激活，初步捕捉特征间的局部组合关系。如公式（4）所示：

$$\mathbf{h}_1 = \sigma(\text{BN}(\text{Conv1d}(\mathbf{v})))$$

其中 σ 代表非线性激活函数 ReLU，BN 代表一维批量归一化。此层将特征维度从 1 提升至 128。

接着，深层语义融合层将通道数分别扩张至 512 和 1024 层，进一步挖掘高阶的非线性空间相关性，这种极宽的网络设计有助于在自监督环境下记录更丰富的特征组合，为下游分类任务留出充足的特征冗余。如公式（5）（6）所示：

$$\mathbf{h}_2 = \sigma(\text{BN}(\text{Conv1d}(\mathbf{h}_1)))$$

$$\mathbf{h}_3 = \sigma(\text{BN}(\text{Conv1d}(\mathbf{h}_2)))$$

然后，经过全局特征聚合层，采用自适应平均池化并展平，保留全局统计特

征,最后通过全连接层将特征投影至 256 维,作为最终的表征向量。如公式 (7) 所示:

$$\mathbf{y} = \text{Pool}(\mathbf{h}_3), \quad \mathbf{y} \in \mathbb{R}^{B \times 1024 \times 1}$$

$$\mathbf{final} = \mathbf{W}\mathbf{y}_{flat} + \mathbf{b}$$

3.3.2 投影器和预测器

在自监督学习过程中,若直接在表示空间进行预测可能会导致表征崩溃,即网络发现无论输入什么图像,只要输出一个全零或常数的向量,损失函数就能变成 0,那么它就会停止学习,最终使得在线网络和目标网络的权重和偏置均趋于零,使得所有流量特征都过于近似,无法学习到有效的区分信息。因此,在 BYOL 模型中引入了投影器和预测器两个组件,从而打破了模型的对称性,构建了一个动态系统,迫使模型必须提取有意义的特征才能维持预测的准确性。

首先,通过编码器 f_θ 和 f_ξ 对输入的原始流量进行编码后,网络流量被转换为向量形式的特征表示 $\mathbf{y}_\theta$ 和 $\mathbf{y}'_\xi$ 。如式 (3.5) 和式 (3.6) 所示,其中 v 和 v' 是经过两种不同数据增强处理后得到的视图, $\mathbf{y}_\theta$ 和 $\mathbf{y}'_\xi$ 分别对应于编码器平均池化层的输出。特征表示 $\mathbf{y} \in \mathbb{R}^d$, 其中 d 是平均池化层输出维度。

$$\mathbf{y}_\theta = f_\theta(v)$$

$$\mathbf{y}'_\xi = f_\xi(v')$$

然后,将得到的特征表示 $\mathbf{y}_\theta$ 和 $\mathbf{y}'_\xi$ 输入到一个由两个全连接层和一个批量归一化组成的多层感知机中。如式 (3.7) 和 (3.8) 所示,分别对两个网络的向量进行处理,先将特征映射到高维空间,经过批量归一化和非线性激活处理后,再将高维的特征空间投影到低维的特征空间,利用高维中间层作为缓冲,确保特征被压缩为 256 维的投影向量时,仍能保留足够的判别信息,最终得到 $\mathbf{z}_\theta$ 和 $\mathbf{z}'_\xi$ 。

$$\mathbf{z}_\theta = g_\theta(\mathbf{y}_\theta) = W_\theta^{(2)} \sigma \left(\text{BN} \left(W_\theta^{(1)} \mathbf{y}_\theta + b_\theta^{(1)} \right) \right) + b_\theta^{(2)}$$

$$\mathbf{z}'_\xi = g_\xi(\mathbf{y}'_\xi) = W_\xi^{(2)} \sigma \left(\text{BN} \left(W_\xi^{(1)} \mathbf{y}'_\xi + b_\xi^{(1)} \right) \right) + b_\xi^{(2)}$$

其中, $\mathbf{W}$ 和 $\mathbf{b}$ 分别表示全连接层的权重和偏置, BN 代表批量归一化层, σ 是非线性激活函数。特征投影的步骤是至关重要的,不仅能够识别出数据增强中的不变性,还能去除对未知协议流量聚类任务没有意义的信息。通过 g_θ 和 g_ξ 的非线性变换,最终 $\mathbf{y}_\theta$ 和 $\mathbf{y}'_\xi$ 中能够保留更多有用的信息。

预测器 q_θ 是在线网络特有的组件,通过引入额外的非线性映射来打破模型对称性。在特征投影处理之后,初始的特征向量被映射到低维向量空间,产生 $\mathbf{z}_\theta$ 和 $\mathbf{z}_\xi$ 。此时,如式 (3.9) 所示,通过在线网络处理的流量需要经过预测器 q_θ 的

处理以获得预测向量 $q_\theta(z_\theta)$ ，而通过目标网络处理的流量则无需此步骤。预测器 q_θ 的网络架构与投影器 g_θ 和 g_ξ 保持一致或高度相似，由两个全连接层和一个批量归一化层组成。

$$q_\theta(z_\theta) = W_\theta^{(4)} \sigma \left(\text{BN} \left(W_\theta^{(3)} z_\theta + b_\theta^{(3)} \right) \right) + b_\theta^{(4)}$$

目标网络没有预测器部分，这种结构上的非对称性是 BYOL 模型的核心。如果在线网络和目标网络完全一样，模型通过简单的恒等映射就能使损失函数为零，从而导致表征崩溃。预测器的加入使得在线网络预测目标网络变成了一个非对称任务，这种不对称性迫使模型去学习数据中更复杂的语义，而不是简单的复制。

3.3.3 损失函数

在 BYOL 方法中，损失函数是模型优化的核心部分，它通过归一化处理和均方误差衡量在线网络的预测与目标网络的投影之间的差异，从而确保模型稳定收敛。为了增强鲁棒性并避免模型坍塌，BYOL 引入了对称损失，即将两个增强视图进行交换，然后分别计算两次的损失函数并相加，从而得到最终总的对称损失。通过最小化对称损失函数，模型能够在不依赖负样本的情况下学习到高质量的图像表示。

在经过上述投影器和预测器的处理后，两个流量序列增强变体分别通过在线网络和目标网络生成预测向量 $q_\theta(z_\theta)$ 和投影向量 z'_ξ 。在线网络预测向量 $q_\theta(z_\theta)$ 的维度与目标网络投影向量 z'_ξ 相同，确保两者在同一特征空间中进行比较。接着，模型通过最小化预测向量 $q_\theta(z_\theta)$ 与目标投影向量 z'_ξ 之间的均方误差来对在线网络的参数进行优化训练。

计算损失函数时，首先对 $q_\theta(z_\theta)$ 和 z'_ξ 进行 $L2$ 正则化，公式如下：

$$\bar{q}_\theta(z_\theta) = \frac{q_\theta(z_\theta)}{\|q_\theta(z_\theta)\|_2}, \quad \bar{z}'_\xi = \frac{z'_\xi}{\|z'_\xi\|_2}$$

其中 $\|\cdot\|_2$ 表示向量的 $L2$ 范数，即向量的欧几里得距离。

然后对两个归一化结果进行均方误差计算，得到初始损失函数，公式如下：

$$\mathcal{L}_{\theta,\xi} = \|\bar{q}_\theta(z_\theta) - \bar{z}'_\xi\|_2^2 = 2 - 2 \cdot \frac{\langle q_\theta(z_\theta), z'_\xi \rangle}{\|q_\theta(z_\theta)\|_2 \cdot \|z'_\xi\|_2}$$

接着需要进行第二次前向传播，交换两个增强视图的输入，将 v 和 v' 分别输入目标网络和在线网络，得到另一个损失函数 $\tilde{\mathcal{L}}_{\theta,\xi}$ 。最后将两次前向传播的损失函数相加，得到最终的对称损失函数：

$$\mathcal{L}_{\theta,\xi}^{BYOL} = \mathcal{L}_{\theta,\xi} + \tilde{\mathcal{L}}_{\theta,\xi}$$

3.3.4 指数移动平均值 (EMA) 更新机制

在线参数更新之后, 还需要对目标网络的参数进行更新, 为了保证学习目标的稳定性, 目标网络的参数 ξ 通过在线网络的参数 θ 的指数移动平均进行更新, 在每个训练步骤中, 给定一个预设的衰减率, 目标网络的参数会根据衰减率, 通过在线网络的参数进行加权更新:

$$\xi_t = \tau \cdot \xi_{t-1} + (1 - \tau) \cdot \theta_t$$

其中, ξ 是目标网络的参数, θ 是在线网络的参数, τ 为衰减率, 用以控制目标网络参数的更新速度, 衰减率的数值通常非常接近 1, 从而保证目标网络为在线网络提供一个相对稳定, 平滑变化的目标。

这种快慢结合的更新机制一方面为在线网络提供训练动力, 如果两个网络完全一样且同步更新, 那模型容易陷入自己预测自己的死循环, 通过不平衡的更新机制, 在线网络能够不断地学习新的特征信息; 另一方面增强了模型的稳定性, 目标网络的参数更新较慢, 其产生的表示空间不会发生剧烈抖动, 是 BYOL 模型在不使用负样本的情况下依然能避免表示崩溃的关键支撑。

3.4 训练优化

3.4.1 学习率调度与 AdamW 优化

在本工作的模型优化阶段, 我们采用了 AdamW 优化器。相比于传统的 Adam 算法, AdamW 通过将权重衰减与梯度更新解耦, 能够更有效地提升模型的泛化能力。初始学习率设定为 2×10^{-5} 。为了实现训练全过程的精细化调控, 引入了 ReduceLROnPlateau 学习率调度策略: 当验证集损失在连续 15 个 Epoch 内未取得显著下降时, 系统将触发学习率衰减机制, 以 0.5 的衰减因子对当前学习率进行调整, 旨在通过更小的步长探测损失函数空间的全局极小值点

3.4.2 针对抖动的回溯策略

针对自监督学习任务中常见的梯度抖动及局部最优陷阱问题, 本文进一步提出并实现了一套基于参数回溯的重置机制。在实验观察中, 深度模型在处理小样本流式数据集时, 往往因其高度非凸的优化目标而陷入训练僵局。为此, 若验证集损失在连续多个 Epoch 内未能刷新最优记录, 系统将自动判定模型进入收敛瓶颈或过拟合状态。此时, 算法将进行回溯处理。首先, 强制回溯并加载历史保存的最优参数模型, 接着, 对学习率执行阶梯式衰减, 最后, 重置优化器的内部状态, 以消除先前错误梯度的惯性影响。这一策略能够增强模型在复杂训练环境下的鲁棒性, 并有效遏制过拟合现象。

3.5 实验设计与结果分析

本节将对所提出的基于 BYOL 的流级别特征分类模型进行全面的实验评估。首先，我们将介绍实验环境的配置，包括硬件和软件环境。接着，详细介绍所使用的数据集及其预处理方法。随后，定义用于评估模型性能的评价指标，并说明模型训练过程中参数设置的细节。最后，与现有的流级别特征分类模型进行对比分析，展示本模型在多个数据集上的表现，并对实验结果进行深入分析。

3.5.1 实验环境

本工作使用的实验硬件设备为 13th Gen Intel(R) Core(TM) i7-13700H (2.40 GHz)，16GB RAM，NVIDIA GeForce RTX 4060 GPU。软件环境方面，操作系统为 Windows 11，使用 Python 3.11 作为主要编程语言。所需要的 Python 库主要包括 scapy，Pytorch，NumPy，Pandas，Scikit-learn 等。实验环境如表 3.1 所示：

名称	类型
处理器	13th Gen Intel(R) Core(TM) i7-13700H (2.40 GHz)
GPU	NVIDIA RTX 4060
运行内存	16.0GB
操作系统	Windows 11
软件平台	Python 3.11

表 3.1 实验环境设置

3.5.2 数据集介绍与预处理

1) 数据集介绍

为了验证本章所提出的分类方法在加密流量分类任务中的有效性，本工作选取了四个在网络流量识别领域常用的公开数据集作为训练与测试样例。

ISCX-VPNnonVPN 数据集：该数据集源自实际网络运行环境，具有较高的真实性和可靠性；包含规模完整的多种协议和环境；包含源 IP、目的 IP、端口、协议、流量大小和时间戳等元数据，方便进行预处理和特征提取；涵盖了通过 VPN 传输的流量和未通过 VPN 传输的流量，且具有多种应用类型，能够满足本文对加密流量特征和行为模式的研究。**ISCX-TorNonTor 数据集：**该数据集侧重于捕获经过洋葱路由器（Tor）多层加密且具备高度混淆特性的匿名流量。涵盖了 Tor 封装与非 Tor 环境下的应用行为，能够检验模型在极端隐私保护及特征强混淆环境下的鲁棒性。**USTC-TFC 数据集：**该数据集根据其原始标签方案将 20 种真实网络流量整合为良性流量与恶意软件流量两大类别，旨在评估模型对非法攻击

及僵尸网络通信的识别精度。**VNAT** 数据集：提供了针对 Skype、Facebook 等十种特定应用程序的细粒度 VPN 流量，并涵盖了关键的命令与控制（command & control, C2）流量场景，为隐蔽通信信道的检测研究提供了数据基础。

在 ISCX VPN-nonVPN 以及 ISCX-TorNonTor 数据集中，原始数据存在标签标注不明确的问题。仅提供了流量文件的描述性信息，而未对其进行精确分类，这导致部分流量文件的类别归属存在歧义，以“Facebook video.pcap”文件为例，该流量文件可能同时符合“浏览器”和“流媒体”两类特征，难以准确归类。为确保实验数据的准确性和模型训练的有效性，本文将容易存在分歧的各类社交媒体流量单独划分为一个新的类别，以区分原有的流量类别，从而形成更为清晰的分类体系。各数据集的具体内容如表 3.2 所示。

数据集	类型	内容
ISCX-VPNnonVPN	Email	Email, Gmail
	Chat	ICQ, AIM
	Streaming	Vimeo, Youtube, Netflix, Spotify
	File transfer	FTPS, SFTP, scp, bittorrent
	VoIP	Voipbuster
	Socialapp	Facebook, Hangouts, Skype
ISCX-TornonTor	Email	Thunderbird, IMAP, POP
	Chat	IAM, ICQ
	Streaming	Vimeo, Youtube, Spotify
	File transfer	P2P, FTP, SFTP, SSL
	Web	Browsing, Google
	Socialapp	Facebook, Hangouts, Skype, Twitter
VNAT	Streaming	Vimeo, Netflix, Youtube
	File transfer	SFTP, RSYNC, SCP
	Chat	Skype
	VoIP	VoIP
	C2	SSH, RDP
USTC-TFC	Benign	Bittorrent, Facetime, FTP, Gmail, MySQL, Outlook, Skype, SMB, Weibo, WorldOfWarcraft
	Malware	Cridex, Geodo, Htbot, Miuref, Neris, Nsis-ay, Shifu, Tinba, Virut, Zeus

表 3.2 数据集内容

2) 数据预处理在实验执行过程中，为了确保评价结果的客观性与泛化性，本

工作对上述所有原始数据进行了统一的预处理与随机划分：其中 60% 的数据用于模型参数的迭代训练，20% 作为验证集用于超参数调优及防止过拟合，剩余 20% 的数据则作为完全独立的测试集，用于最终衡量模型在未知样本上的分类效能。




图 3.4 数据预处理流程

在数据预处理阶段，本工作首先利用由源 IP、目的 IP、源端口、目的端口及协议类型构成的五元组作为关联标识，将零散的数据包聚合为具有逻辑意义的网络流。为确保统计特性的鲁棒性并剔除网络扫描或无效连接产生的噪声干扰，本工作对数据包数量少于 5 个的短流进行了过滤剔除。接着，预处理过程从行为模式与内容结构两个维度同步进行多维特征的联合表征：在流级别维度，提取各流前 16 个数据包的应用层负载长度，并对长度不足者实施零填充以规整化为定长向量，旨在有效捕捉加密流量原始的行为序列特征；在包级别维度，则截取每个流的前 5 个数据包并提取其 IP 数据报头，同时剔除源/目的 IP 地址字段，以引导模型学习更具泛化意义的协议结构特征，包级别特征的相关原始数据将为后续章节提出的深度学习方法提供输入支持。最后，针对网络流量数据集中普遍存在的类别不平衡问题，本工作引入了合成少数类过采样技术（SMOTE）与随机欠采样相结合的混合采样策略，通过将各类别样本量统一均衡至各类别数量的中位数，有效缓解了模型对多数类样本的过拟合风险，确保了分类决策边界的公

正性与准确性。预处理过程如图 3.4 所示。

3.5.3 评价指标

网络流量识别分类和异常检测，本质上都属于模式识别中的分类问题，这类问题的核心是通过学习流量特征的模式差异，建立从网络数据到类别标签的映射关系。为全面评估分类模型性能，本文采用当前主流的四个评价指标来完成模型的性能评估，分别是准确率（Accuracy, Acc）、精确率（Precision, Pr）、召回率（Recall, Rc）、F1 分数（F1-Score）。同时，为了更直观地展示模型在不同类别上的分类效果。

在多元分类任务中,对于特定类别 C_i ,相关参数定义如下:真正例 (True Positive, TP):实际属于 C_i 且被模型正确预测为 C_i 的样本数量。假正例 (False Positive, FP):实际不属于 C_i 但被模型错误预测为 C_i 的样本数量。假负例 (False Negative, FN):实际属于 C_i 但被模型错误预测为其他类别的样本数量。真负例 (True Negative, TN):实际不属于 C_i 且被模型正确预测为其他类别的样本数量。基于这些定义,上述四个评价指标的计算公式及物理意义如下:

(1) 准确率: 正确分类的样本总数占测试集样本总数的比例,用以评价模型在全数据集上的整体分类效能:

$$\text{Accuracy} = \frac{\sum_{i=1}^n TP_i}{N}$$

其中 n 表示类别总数, N 表示测试集样本总数。

(2) 精确率: 在所有被预测为类别 C_i 的样本中,实际属于该类别的比例,反映了模型对特定类别预测结果的可靠性。

$$\text{Precision}_i = \frac{TP_i}{TP_i + FP_i}$$

(3) 召回率: 在所有实际属于类别 C_i 的样本中,被模型正确识别出的比例,体现了模型对目标类别样本挖掘的完整性。

$$\text{Recall}_i = \frac{TP_i}{TP_i + FN_i}$$

(4) F1 分数: 精确率和召回率的调和平均数,综合考量模型在查准与查全两个维度的平衡表现。

$$\text{F1-Score}_i = 2 \times \frac{\text{Precision}_i \times \text{Recall}_i}{\text{Precision}_i + \text{Recall}_i}$$

3.5.4 参数设置

在本工作中,模型的参数配置旨在平衡自监督学习的表征能力与网络流量数据的计算效率。首先,在骨干网络方面,我们设计了一个深层 1D-CNN 结构,特征通道从输入的 16 维逐步扩张至 1024 维,这种宽通道设计能够有效捕捉流

类别	参数名称	配置数值
训练基础参数	批大小 (Batch Size)	256
	最大迭代轮数 (Epochs)	500
	初始学习率 (Learning Rate)	2×10^{-5}
	优化器 (Optimizer)	AdamW
BYOL 核心参数	投影维度 (Projection Size)	256
	隐藏层维度 (Hidden Size)	4096
	动量系数 (EMA Decay)	0.996
编码器结构	输入特征维度	16
	卷积通道数	$128 \rightarrow 512 \rightarrow 1024$
	卷积核大小 (Kernel Size)	3
	池化方式	AdaptiveAvgPool1d
数据增强	高斯噪声标准差	0.05
	随机缩放范围	[0.8, 1.2]
	掩码比例 (Masking Ratio)	0.1
早停与调度	早停耐心值 (Patience)	100
	抖动回溯阈值 (Decay Patience)	20

表 3.3 模型及训练参数设置

量序列中微小的统计波动。编码器最终将高维特征压缩为 256 维的向量，作为下游任务的通用表征。在 BYOL 框架配置上，投影器和预测器均采用了多层感知机结构，其中隐藏层维度设定为 4096，这种漏斗形结构有助于在投影空间中进行更复杂的非线性变换，防止表征崩溃。为了维持训练过程中的目标稳定性，目标网络的指数移动平均动量系数设定为模型默认的 0.996，确保目标网络参数能够平滑地演进，从而为在线网络提供一致的优化目标。数据增强策略是模型捕捉不变性的核心。通过加入标准差为 0.05 的高斯噪声、0.8 至 1.2 倍的随机缩放以及 10% 的特征掩码，模型被迫在数据不完整或存在测量误差的情况下提取核心语义特征。最后，在优化策略上，模型采用了 AdamW 优化器，并配合 2×10^{-5} 的低学习率以确保微调过程的稳定性。同时，引入了回溯重置机制：当验证集损失连续 20 个 Epoch 无改善时，系统会回滚至历史最佳权重并降低学习率，这种策略结合 100 个 Epoch 的早停机制，能够提升模型在复杂流量数据集上的收敛质量。具体的参数设置如表 3.3 所示。

3.5.5 对比算法

为了充分验证本文所提出的基于 BYOL 的流级别特征分类模型在加密流量识别任务中的有效性，我们选择了当前领域内具有代表性的几种流级别特征分类算法作为对比对象。这些算法涵盖了传统机器学习方法、基于深度学习的方法以及对模型进行消融处理的方法，能够全面展示本模型在不同类型算法中的性能优势。具体的对比算法包括：

(1) 支持向量机 (SVM)：作为传统的机器学习方法，SVM 在流量分类任务中以其良好的泛化能力和对高维数据的适应性而被广泛应用。我们将使用原始数据包长度序列来训练 SVM 模型，以评估其在加密流量分类任务中的表现。

(2) FS-Net：FS-Net 是在深度学习领域经典的端到端加密流量分类框架，且在流量分类领域是最常用的对比模型之一。采用了基于多层双向门控循环单元 (bi-GRU) 的编码器-解码器架构，其核心设计思想在于引入了重构机制。在该框架下，模型不仅通过有监督学习进行应用分类，还通过无监督的重构任务，要求解码器根据编码器提取的特征还原原始流量序列，从而增强特征表示的判别能力与鲁棒性。我们使用每个数据流的前 100 个数据包长度序列作为输入特征，训练 FS-Net 模型。

(3) Base-noBYOL：为了验证本文所提出的增强函数和模型架构设计对性能提升的贡献，我们还将设计了一个不涉及 BYOL 增强处理的基础版本作为对比算法。该版本将仅使用原始数据包长度序列进行训练，并且不包含任何数据增强与对比学习操作，同时保持分类器的各项结构与设置不变。通过与 Base-noBYOL 的对比，我们能够量化增强函数在提升模型性能方面的作用。

3.5.6 实验结果分析

在本节中，我们将对所提出的基于 BYOL 的流级别特征分类模型与上述对比算法在多个数据集上的实验结果进行详细分析。首先，我们将展示各算法在测试集上的准确率、精确率、召回率和 F1 分数等评价指标的具体数值，并通过表格和图形的形式进行比较。四个数据集的实验结果如表 3.4 所示，其中 Precision, Recall, F1-Score 的值为每一个类别对应值的平均数。

从整体实验数据来看，本章提出的方法 BYOL-Ours 在 ISCX-VPNnonVPN、ISCX-TornonTor、USTC-TFC 和 VNAT 四个主流数据集上均取得了最优的分类表现。在各项核心评估指标中，本模型不仅显著超越了基于传统机器学习的 SVM 算法，且相较于不经过增强处理 and 对比学习加强的 Base-noBYOL 框架在准确率上实现了大幅度跃升，平均提升幅度接近 9% – 12%。这有力地证明了针对加密流量特性所做的 BYOL 架构改良与增强函数优化，能够让模型更精准地捕捉报文流中的时空关联特征。与在流量分类领域广泛使用的 FS-Net 方法相比，本章

数据集	方法	Accuracy	Precision	Recall	F1-Score
ISCX-VPNnonVPN	SVM	63.45%	64.97%	63.45%	62.82%
	FS-Net	86.20%	86.70%	86.14%	86.14%
	Base-noBYOL	78.76%	79.29%	78.71%	78.53%
	BYOL-Ours	88.41%	88.66%	88.38%	88.32%
ISCX-TornonTor	SVM	65.2%	64.1%	63.9%	64.0%
	FS-Net	87.02%	87.08%	87.01%	86.97%
	Base-noBYOL	83.30%	83.72%	83.30%	83.13%
	BYOL-Ours	92.03%	91.94%	91.99%	91.94%
USTC-TFC	SVM	84.90%	87.56%	84.90%	84.63%
	FS-Net	92.67%	93.45%	92.51%	92.62%
	Base-noBYOL	88.44%	90.53%	88.57%	88.32%
	BYOL-Ours	97.81%	97.85%	97.82%	97.81%
VNAT	SVM	68.60%	61.14%	68.60%	61.91%
	FS-Net	93.40%	93.19%	92.62%	92.77%
	Base-noBYOL	82.00%	84.04%	81.70%	80.92%
	BYOL-Ours	94.01%	93.87%	93.95%	93.88%

表 3.4 不同数据集上的对比实验结果

提出的方法依然在所有测试场景中保持领先，尤其在处理高度混淆的匿名流量与隧道流量时，展现出了更强的判别力与稳定性。

在 ISCX-VPNnonVPN 与 ISCX-TornonTor 这两类高难度数据集上，本章提出的方法表现尤为突出。在 VPN 隧道识别任务中，由于流量经过二次封装导致特征高度平滑，传统方法如 SVM 仅能达到 63.45% 的准确率，而本章提出的方法成功将其准确率提升至 88.41%。类似地，在面临具有多层加密与高度匿名特性的 Tor 流量时，本模型取得了 92.03% 的准确率，相较于 FS-Net 领先了约 5%。这说明本算法通过优化的对比学习机制，能够有效过滤加密层带来的噪声干扰，从看似随机的数据分布中提取出具有高度区分度的底层协议表征，从而在复杂多变的加密隧道分类中保持高水准的分类性能。

在安全监测与实际应用环境的验证中，模型在 USTC-TFC 与 VNAT 数据集上的表现进一步证明了其工程应用价值。在涵盖多种恶意流量的 USTC-TFC 数据集上，本章提出的方法取得了最好的性能表现，极高的精确率与召回率意味着模型在恶意流量检测任务中具有极低的误报与漏报概率，这对于构建高效的网络防御体系至关重要。而在模拟真实多样化应用场景的 VNAT 数据集中，与对比模型 FS-Net 相比，本章提出的方法通过更健壮的流级别特征提取的方式实现了

分类性能的跨越，准确率达到 94.01%。综合以上分析，本研究所提模型在分类精度与泛化能力上均达到了先进水平，能够有效应对加密网络流量中的分类问题。

3.6 本章小结

在本章中，我们详细阐述了一种基于自监督学习架构的流级别特征分类方法，旨在解决加密网络流量在复杂环境下的特征提取与分类难题。该方法以非对称对比学习架构 BYOL 为核心，通过无标签流量数据上进行自编码学习，提取具有强鲁棒性的流级特征表示，并将其成功应用于下游的分类任务。

首先，针对真实网络环境中常见的丢包、乱序及加密技术带来的流量变异问题，本章设计了两种针对性的增强函数。通过噪声注入模拟数据包长度的细微波动，以及利用尺度缩放与随机遮蔽模拟隧道协议头部开销和网络拥塞导致的丢包场景。这些增强操作有效地构建了差异化的流量变体，迫使模型学习数据中隐含的本质规则与语义不变性。

在模型架构设计方面，本章将原有的二维图像处理骨干网改良为适应一维流数据的一维卷积神经网络（1D-CNN），并引入了由投影器、预测器构成的非对称双网架构。通过在线网络与目标网络之间的指数移动平均（EMA）更新机制与对称损失函数，模型在不依赖负样本的情况下有效避免了表征崩溃，确保了特征提取的高质量与稳定性。

最后，本章在 ISCX-VPNnonVPN、ISCX-TorNonTor、USTC-TFC 及 VNAT 四个主流数据集上进行了广泛的对比实验。实验结果表明，该方法在准确率、精确率、召回率及 F1 分数等核心指标上均显著优于传统的支持向量机（SVM）和经典的 FS-Net 模型。特别是在面对高度混淆的匿名流量和复杂的隧道流量时，本模型表现出了卓越的判别力与泛化性能，验证了自监督流级特征提取在加密流量识别领域的工程应用价值。

第 4 章 基于融合特征的分类方法

在上一章中，我们介绍了基于 BYOL 模型的流级特征分类方法，该方法利用数据包长度序列作为流级别特征的原始表示，在处理加密网络流量时展现出了良好的分类性能。然而，仅依赖单一维度的流级别特征在应对复杂的真实网络环境时，往往难以全面且细致地捕捉流量模式的深层异构性。

图 4.1 为 VNAT 数据集中，提取前 16 个数据包和前 100 个数据包作为原始流量的分类结果混淆矩阵，可以看出：在仅提取 16 个数据包长度序列的短序列情况下，VNAT 数据集中的 C2 和 file 类别存在严重的混淆情况，近 50% 的 C2 类别流量被误分类为 file 类别。而将数据包数量提升至 100，提取长序列以后，C2 被误分类的情况得到缓解，但却引发了过矫正问题，超过 10% 的 file 流量误分类为 C2 类别。这种分类性能的震荡现象表明，这两种流量在数据包长度序列上的特征表示具有极高的相似度。仅凭流级特征，模型难以精准区分两者在行为模式上的细微差别，从而导致分类边界模糊，陷入分类性能的瓶颈。

针对上述挑战，本章提出了一种双模态特征融合的分类架构。首先，为了弥补流级别特征在微观表现力上的不足，我们引入了基于 n-gram 技术的包级别特征提取方法，旨在从数据包内容中挖掘更具辨别力的模式特征。其次，考虑到流级特征与包级特征在信息贡献度上的差异性，本章进一步设计了一种基于注意力机制的特征融合方案。该方案能够动态地捕捉并加权不同尺度的关键信息，通过流级别与包级别特征的深度互补，构建出一个鲁棒性更强、识别精度更高的加密流量分类模型，旨在从根本上缓解复杂流量类别间的混淆问题。

Test Classification Report:						Test Classification Report:					
		precision	recall	f1-score	support			precision	recall	f1-score	support
	chat	1.0000	1.0000	1.0000	194		chat	0.9510	1.0000	0.9749	194
	file	0.6771	0.9949	0.8058	196		file	0.9058	0.8827	0.8941	196
	streaming	0.9862	0.9817	0.9839	218		streaming	0.9855	0.9358	0.9600	218
	VoIP	0.9902	1.0000	0.9951	202		VoIP	0.9902	1.0000	0.9951	202
	C2	0.9897	0.5053	0.6690	190		C2	0.8608	0.8789	0.8698	190
	accuracy			0.9010	1000		accuracy			0.9400	1000
	macro avg	0.9286	0.8964	0.8908	1000		macro avg	0.9387	0.9395	0.9388	1000
	weighted avg	0.9298	0.9010	0.8945	1000		weighted avg	0.9404	0.9400	0.9399	1000

Normalized Confusion Matrix (row-wise):						Normalized Confusion Matrix (row-wise):					
	chat	file	streaming	VoIP	C2		chat	file	streaming	VoIP	C2
chat	100.0%	0.0%	0.0%	0.0%	0.0%	chat	100.0%	0.0%	0.0%	0.0%	0.0%
file	0.0%	99.5%	0.5%	0.0%	0.0%	file	0.0%	88.3%	0.0%	0.0%	11.7%
streaming	0.0%	0.5%	98.2%	0.9%	0.5%	streaming	3.7%	0.0%	93.6%	0.9%	1.8%
VoIP	0.0%	0.0%	0.0%	100.0%	0.0%	VoIP	0.0%	0.0%	0.0%	100.0%	0.0%
C2	0.0%	48.4%	1.1%	0.0%	50.5%	C2	1.1%	9.5%	1.6%	0.0%	87.9%

图 4.1 两个混淆矩阵

4.1 系统模型

本章提出了一种基于双模态融合特征的深度学习网络流量分类模型。该模型旨在解决单一维度特征在面对复杂加密流量时表达能力不足的问题。系统整体架构由三个核心阶段组成。首先是包级别特征的增强型 N-gram 序列建模，用于挖掘数据报头内部的字节结构信息和文本顺序信息；其次是基于交叉注意力机制的特征融合模块，将流级别特征与包级别特征进行非线性对齐与融合，利用交叉注意力机制挖掘两种维度特征间的相关性，并在训练过程中动态地调节两种特征的权重从而达到更好的融合效果。最后，我们还设计了深度残差分类器 MLP 分类器用于进行分类任务，分类器主体采用了由多个残差块堆叠形成的网络结构，每个残差块内部均包含全连接层、批归一化与 Dropout 结构，通过引入跳跃连接机制，有效缓解了深层网络中的梯度消失问题，并提升了模型的表达能力和泛化性能，确保模型能够精准捕获复杂的流量分类边界并最终输出准确的流量类别。

4.2 包级别特征提取

在传统的基于数据包内容的分类方法中，通常依赖数据包的有效载荷作为核心识别特征。然而，有效载荷中往往包含用户身份、通信内容及行为偏好等高度敏感的信息，直接将其作为深度学习模型的输入，极易引发潜在的隐私泄露风险与伦理争议。此外，随着各种加密协议的普及，有效载荷呈现高度熵增的伪随机状态，导致传统的载荷分析手段较难达到准确的分类效果。

Hu 等人的研究发现，虽然加密协议屏蔽了应用层内容，但网络层与传输层的数据包首部数据仍保留了丰富的协议交互逻辑与特性。其实验结果表明，仅通过提取报文头部的字节序列进行建模，即可在多种复杂业务场景下实现与全载荷方案相媲美的分类精度。基于此，本工作在确保用户隐私边界的前提下，将有效载荷数据提出，仅使用 IP 数据报头部数据作为模型的原始输入。通过对报文头部进行结构化特征挖掘，旨在构建一种既符合隐私保护要求，又能适配加密网络环境的分类模型。

4.2.1 报文首部截取与预处理

为了捕获网络协议交互的核心语义并构建特征输入，我们首先对原始流量进行流分割，基于五元组信息源 IP、目的 IP、源端口、目的端口及传输层协议将捕获的数据包切分为逻辑连接的数据流。接着预先截取每个流前 5 个数据包的 IP 报文首部作为原始特征输入。

在特征空间构建过程中，需针对报文首部的结构特性进行处理。标准的 IPV4

首部包含 20 字节的固定长度字段，其结构如表 4.1 所示。IP 分组报头涵盖了段版本、首部长度、优先级与服务类型、总长度、标识、标志、段偏移、生存时间、协议、校验和、源 IP 地址和目的 IP 地址这 12 个关键字段。然而，源/目的 IP 地址字段与特定的网络拓扑配置高度耦合，其数值分布更多反映了网络部署环境而非业务流本身的协议特征。从网络流量分类任务的角度来看，这两个字段属于冗余信息，会影响模型的泛化能力和分类结果。因此，本工作在预处理阶段将源/目的 IP 地址字段视为剔除，从而实现特征降维与关键语义的聚焦。

0-3 bit	4-7 bit	8-15 bit	16-18 bit	19-31 bit
版本	首部长度	服务类型	总长度	
标识			标志	片偏移
生存时间	协议	首部校验和		
源 IP 地址				
目的 IP 地址				
可选字段				填充

表 4.1 IP 数据报头结构

4.2.2 N-gram 嵌入处理

在现有的基于数据包内容的分类方法中，主流方法通常将报文视为独立的字节流，并将每个字节视为离散的输入特征。然而，IP 数据包的字节序列具有比自然语言更为严谨的结构化语义。报文首部中的多个连续字节通常共同构成一个具有明确物理含义的字段，例如总长度字段由两个字节组成，段偏移字段涉及位运算关联。此外，报文首部字节间存在固定的位置关系，这些结构化信息与顺序特征对于识别协议模式至关重要。融入这些信息可以增强特征表示。为了充分挖掘字节间的结构化信息与顺序特征，本工作引入了 N-gram 嵌入方案。通过在预处理后的报文首部滑动取窗，提取具备上下文关联的语义特征。

本工作使用大小为 $n \in \{1, 2, 3\}$ 的滑动窗口对报头数据进行扫描。将 1 字节、2 字节和 3 字节的段作为特征生成的标记，所有窗口的步长均为 1。对于预处理过程中获得的 IP 数据包报头，1-gram 捕捉孤立的字节信息，而 2-gram 和 3-gram 通过构建长度分别为 2 和 3 的字节组合，提取报文内部的结构化信息与顺序特征。最后将得到的嵌入式特征按顺序连接起来，形成最终的包级特征。整个过程如图 3 所示。

对于 1-gram 得到的字节形式特征，我们对其字节流进行归一化处理。以此




图 4.2 n-gram 嵌入处理

消除量纲差异并加速深度学习模型的梯度收敛。本工作将原始字节在 $[0, 255]$ 范围内的取值线性映射至 $[-1, 1]$ 的数值区间。这种处理方式在保持报文首部关键字段原始分布特征的同时，通过中心化与缩放操作提升了线性特征的分布稳定性，为后续通过非线性模型提取包级别特征奠定基础。

而对于 2-gram 和 3-gram 得到的字节组合特征，我们将其十六进制字节组合转换为对应的十进制数值 $ngram_{dec}$ 。通过这种映射，原始的离散字节被转换至具备数值统计意义的高维特征空间中。由于网络协议中存在诸如标识符、校验和或高精度时间戳等字段，其产生的 $ngram_{dec}$ 往往呈现极高的随机性以及长尾分布。若采用传统的线性归一化方法，由于 n-gram 理论最大值 $16^{2n} - 1$ 极大，会导致大部分关键信息被压缩至极小的数值区间内，产生严重的特征淹没效应。因此，我们引入了非线性对数变换来缓解这一问题。

$$\log_val = \ln(1 + ngram_{dec})$$

通过对 $ngram_{dec}$ 进行对数变换，模型能够在保持原始数值单调性的前提下，有效地压缩高值区间、扩张低值区间，同时保留特征之间的相对关系，从而缓解数据分布极度不均的问题。随后，利用理论最大值的对数映射 $\log_max = \ln(1 + \max_val)$ 对数据进行重缩放，将其映射至与 1-gram 特征相同的 $[-1, 1]$ 区间内，确保不同 n-gram 特征在同一数值范围内进行融合与学习。

$$normalized = 2 \times \frac{\log_val}{\log_max} - 1$$

这种处理方式不仅保留了数据报头之间的词组信息和各关键字之间的顺序信息，还有效地压缩了极端值的影响，使得模型能够更好地学习到数据包级特征中的细微差异，从而提升分类性能。

为了使后续下游分类任务能够正常进行，我们还将处理后的特征进行进行维度对齐，从而保证分类模型输入张量的维度一致性。针对通信持续时间较短、

数据包总数不足 5 个的短流，模型通过计算现有长度来动态生成占位包。填充数值统一设定为 -1，以区分于正常数据包的特征值。这种填充方式不仅保证了多级特征按顺序连接后的特征向量长度一致，还通过显式的边界填充符号降低了填充数据对模型真实特征学习的干扰，帮助模型在训练过程中识别并适应不同长度流量的特征分布差异，从而提升模型的泛化能力和分类性能。

4.3 交叉注意力特征融合机制

在完成上述包级别特征与上一章流级别特征的提取后，我们还需要将两个模态的两类特征进行高效地融合，从而提升模型的分类性能。传统的特征融合方法多采用简单的向量拼接或加权求和，这种线性处理方式往往忽略了流级别特征与包级别特征之间深层的非线性关联，难以充分发掘不同模态特征在刻画特定网络行为时的互补潜力。为了深度挖掘这种关联信息，本工作构造了基于交叉注意力机制的特征融合模块。该模块通过模拟人类视觉注意力的分配逻辑，以流级别特征作为引导信号，动态地在包级别特征序列中检索并聚焦于关键的报文模式。通过在隐空间内进行特征重构与空间对齐，该机制不仅能够自动学习不同模态特征的贡献权重，还能有效缓解异构数据间的维度冲突，从而生成具备高度判别力的融合特征，为后续分类网络提供更加有助于流量分类的输入。

4.3.1 线性投影与空间对齐

由于流级别特征 F 侧重于刻画通信过程的时间序列信息与包级别特征 P 侧重于刻画数据包的结构化信息，两类特征在特征维度、取值范围以及语义空间上存在显著差异，直接进行向量拼接或加权融合会导致维度失配，并可能因特征量级不一而引发特征淹没，进而造成关键信息的丢失。为此，本模块首先引入了维度对齐机制，通过学习两个独立的线性全连接层，将异构的流级别特征空间与包级别特征空间映射至一个统一的、高维的隐空间中。从而实现维度的强制对齐，并对两类特征进行重新编码，使其在同一语义空间内进行交互与融合。

$$f_{align} = \text{LayerNorm}(W_f \cdot F + b_f)$$

$$p_{align} = \text{LayerNorm}(W_p \cdot P + b_p)$$

其中， $W_f \in \mathbb{R}^{d_{align} \times d_f}$ 和 $W_p \in \mathbb{R}^{d_{align} \times d_p}$ 为可学习的投影权重矩阵， b_f 与 b_p 为对应的偏置项， d_{align} 表示对齐后的空间维度。

4.3.2 交叉注意力流

在完成空间对齐后，本工作利用交叉注意力机制实现流级别特征与包级别特征之间的深度交互。如图 4.3 所示，与传统自注意力机制中 Q 、 K 、 V 均来自同




图 4.3 交叉注意力机制

一模态的逻辑不同，交叉注意力机制旨在建立不同模态特征间的协同映射关系。在本工作中，我们利用流级特征 f_{align} 进入注意力流生成查询向量 Query，主动检索包级特征 p_{align} 生成的键向量 Key 和值向量 Value。利用较为宏观的数据包长度序列信息去询问相对局部的数据包报文信息。具体公式如下：

$$Q = f_{align}W^Q + b^Q$$

$$K = p_{align}W^K + b^K$$

$$V = p_{align}W^V + b^V$$

其中， $W^Q, W^K, W^V \in \mathbb{R}^{d_{align} \times d_k}$ 为可学习的权重矩阵， b^Q, b^K, b^V 为相应的偏置项。本工作采用了多头注意力配置，将隐空间划分为 h 个独立子空间，每个子空间的维度为 $d_k = d_{align}/h$ ，这种并行注意力机制允许模型从多个表示子空间中同时捕捉流特征与包特征之间的复杂关联。

为了衡量两类特征的相关程度，通过点积运算计算 Q 与 K 在隐空间内的相似度。考虑到在高维空间下，点积结果的量级增大可能导致 Softmax 函数出现梯度消失问题。本工作采用了缩放点积处理对注意力分数进行修正，并在之后进行 Softmax 归一化，从而得到注意力权重分布 α ，最后利用这个权重加权求和 V ，

得到融合后的特征表示，其完整的计算流如下：

$$f_{fused} = \sum \alpha_i V_i = \text{Attention}(Q, K, V) = \text{Softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

其中 QK^T 计算了流特征与包特征在隐空间内的投影重合度。得分越高，代表包级别特征对当前业务类型的判别贡献越大。 Softmax 函数输出的权重分布 α 则用于刻画包级别特征对当前特定流类型的判别贡献度。最终，通过对值向量 V 进行加权聚合，模型生成兼具全局规律与局部指纹的融合特征表示 f_{fused} 。这种融合方式有效地缓解了由于加密导致的数据冗余问题，通过注意力权重的自动分配，模型能够忽略报头中的噪声字段，而聚焦于对分类任务真正有益的关键字段组合，并利用包级别特征的局部信息对全局的流级别特征进行细节补充，从而弥补单一模态特征在刻画复杂流量模式时表达不足的问题，提升模型的分类性能和泛化能力。

4.4 深度残差分类器

经过上一节的交叉注意力模块实现跨维度的特征捕捉与融合后，系统生成的融合特征 f_{fused} 已具备了高度精炼的流量指纹特征。为了将这些抽象的语义特征进一步映射至最终的流量类别空间，本工作设计了一种基于深度残差网络的多层感知机架构作为主分类器。传统的线性堆叠网络在处理高维加密流量指纹时，随着网络深度的增加，容易产生的梯度消失或退化问题，为此，我们引入了跳跃连接机制，允许底层特征流通过恒等映射直接跨越多个非线性层进行传递，使得网络只需学习输入与输出之间的残差映射，而非完整的映射函数，确保了梯度流在深层网络中的高效反向传播。分类器的具体结构如图 4.4 所示。

阶段	对应代码组件	功能描述
输入层	<code>nn.Linear(256, 1024)</code>	将注意力融合后的 256 维向量映射到 1024 维的高维空间，扩充特征表达。
残差块 (x5)	<code>ResidualBlock</code>	核心主干。 每个块内包含： <code>Linear -> BN -> ReLU -> Linear -> BN</code> 。
跳跃连接	<code>out += residual</code>	关键机制。 在每个残差块内部，将输入直接加到输出上，防止梯度消失。
输出层	<code>nn.Linear(1024, 6)</code>	将高维特征压缩至 6 个类别得分 (Logits)，对应不同的业务类型。

图 4.4 分类器结构

4.4.1 输入层

分类器的输入层用于接收来自交叉注意力机制生成的融合特征向量 f_{fused} 。在进入残差主干网络之前，首先通过一个全连接层将维度从融合空间维度映射至更高维的隐藏空间，接着经过一个批量归一化层和非线性激活函数，将初步融合的特征进行非线性扩充，从而构建出表达能力更强的稀疏表征。

$$h_0 = \text{ReLU}(\text{BN}(W_{init}f_{fused} + b_{init}))$$

4.4.2 深层残差主干网络

为了从融合特征中提取具有强判别力的分类特征，本工作构建了一个由多个残差块纵向堆叠而成的深层 MLP 架构作为分类网络的主干。该部分作为整个分类系统的决策核心，通过复杂的非线性演化，将融合特征映射至高维线性可分的业务空间。每个残差块采用双层线性映射结构，块内包含两次全连接映射。第一层为初步交互层，负责捕捉输入特征分量间的初步非线性交互，并将融合特征映射至更高阶的表示空间。第二层为特征精炼层，对上述高阶表示进行二次提纯，滤除噪声冗余，保留最具类别区分度的关键特征。这种双层结构模拟了小型的编码解码过程，增强了模型对复杂加密协议特征的非线性拟合精度。

为了确保深层模型在训练过程中的数值稳定性与泛化性能，在每层全连接计算之后，均嵌入了批量归一化层以稳定训练过程中的特征分布，加速模型的收敛速度。接着通过 ReLU 激活函数引入非线性变换，确保特征框架具备足够的非线性复杂度，提升模型的表达能力。此外，每个残差块内部的两个全连接层之间设置 Dropout 层，通过训练阶段随机使部分神经元失活，强迫模型学习更加独立的特征表示，从而防止出现过拟合现象，以增强模型的泛化能力。

此外，本工作构建的残差网络的核心在于引入了跳跃连接机制，在每个残差块的末端输出前，建立一条跨越两层全连接变化的恒等映射通道。使得每个残差块中第一个全连接层的输入能够直接与第二个全连接层的输出相加，从而形成跳跃连接。在反向传播过程中，由于存在跳跃连接路径，梯度可以直接通过加法算子回传至前层，确保了深层参数能够得到有效更新。这种设计能够缓解深层网络中的梯度消失问题，使得模型能够在增加网络深度的同时，保持高效的梯度流动和稳定的训练过程。设第 i 个残差块的输入向量为 $\mathbf{x}_i$ ，该网络的具体处理流程可描述如下：

$$\mathbf{y}_i = \sigma(\text{BN}(W_{i,1}\mathbf{x}_i + \mathbf{b}_{i,1}))$$

$$\mathcal{F}(\mathbf{x}_i) = \text{BN}(W_{i,2}\mathbf{y}_i + \mathbf{b}_{i,2})$$

$$\mathbf{x}_{i+1} = \sigma(\mathcal{F}(\mathbf{x}_i) + \mathbf{x}_i)$$

其中, W 和 b 分别表示两个全连接层的权重和偏置, BN 表示批归一化, σ 表示 ReLU 激活函数。 $\mathcal{F}(\mathbf{x}_i)$ 代表该残差块拟合的特征映射。

4.4.3 输出层逻辑

分类器的最后一层为全连接层, 其核心职能是将高度非线性的隐空间表征压缩并映射至预定义的 n 维业务类别空间, 每个维度分别对应一类特定的加密网络业务。输出层产生的原始逻辑得分通过 Softmax 函数执行概率标准化映射

$$P(y = k|\mathbf{x}) = \exp(z_k) / \sum_j \exp(z_j)$$

其中 z_k 代表第 k 个类别的预测得分。通过这一变换, 模型将抽象的特征分布转化为具有直观物理意义的类别概率分布, 最终选取概率峰值对应的索引作为流量分类的最终决策结果。

4.5 训练优化

4.5.1 学习率调度

本模型的训练过程采用了基于验证集表现驱动的动态优化策略, 旨在平衡收敛速度与全局搜索能力。核心优化器选用 AdamW 算法, 利用其解耦权重衰减的特性来增强正则化效果, 并配合 OneCycleLR 学习率调度策略, 在训练初期快速爬升以越过局部最优陷阱, 并在后期执行余弦退火降温以实现参数的精确收敛。这种策略有助于模型跳出局部最优解, 在训练中寻找全局最优点。为进一步防止过拟合并提升自动化训练水平, 系统采用与上一章类似的回溯降温与早停机制: 当验证集准确率在预设的多个耐心周期内未见提升时, 训练程序将自动回溯至历史最优权重状态, 并按固定比例下调学习率。损失函数方面则统一采用交叉熵损失, 通过最小化预测概率分布与真实标签之间的 Kullback-Leibler 散度, 引导模型在迭代中不断精炼决策边界。

4.6 实验设计与结果分析

本文将对基于融合特征的分类模型进行全面的实验评估。在对比试验阶段, 所使用的实验环境, 数据集以及针对实验结果的评估标准与上一章一致, 在此不做过多赘述。此外, 为了验证融合特征方法相比于仅依赖流级别或包级别特征的单模态特征方法在分类性能上的优越性, 以及验证融合特征所拥有的两类特征互补优势, 我们还将通过混淆矩阵来揭示模型在各个类别上的误分类情况。

4.6.1 参数设置

在网络结构层面，为了平衡特征表达能力与计算开销，特征融合空间的对齐维度 d_{align} 设置为 256，多头注意力机制的头数 h 定为 8。分类器内部通过 5 层残差块进行深层建模，每层隐藏单元的宽度保持在 1024 维，以充分容纳高维流形特征。在优化算法方面，采用 AdamW 优化器，并配置 10^{-3} 的初始学习率，利用 OneCycleLR 策略在 100 个 Epoch 的训练周期内执行动态调整。为抑制过拟合，模型引入了 0.2 的 Dropout 概率以及 10^{-4} 的权重衰减因子。此外，训练过程通过验证集性能进行实时驱动，设置早停阈值为 10，并配合学习率回溯降温机制，以确保模型在最优参数空间内平稳收敛。具体的参数设置如表 4.2 所示。

类别	参数名称	配置数值
架构参数	隐空间对齐维度 (d_{align})	256
	注意力头数 (h)	8
	残差块数量 (Blocks)	5
	隐藏层神经元数	1024
优化策略	初始学习率 (LR)	1×10^{-3}
	训练周期 (Epochs)	100
	批大小 (Batch Size)	128
	学习率调度器	OneCycleLR
正则化	丢弃率 (Dropout)	0.2
	权重衰减 (Weight Decay)	1×10^{-4}
	早停阈值 (Patience)	10

表 4.2 模型及训练参数设置

4.6.2 对比算法

为了充分验证本章所提出的基于融合特征流量分类模型在加密流量识别任务中的有效性以及相比于单模态模型的优越性，我们选择了当前领域内具有代表性的包级别特征分类算法和融合特征分类算法作为对比对象。此外我们对本章提出的模型进行了消融处理，仅使用包级别的特征作为分类特征输入到分类器中作为对比消融实验进行参考。以上的对比实验能够全面展示本模型在不同类型算法中的性能优势。具体的对比算法包括：

(1) 1D-CNN: Wang 等人提出的 1D-CNN 流量分类模型是加密流量分类领域端到端学习路径的最常用的基准模型之一，其核心逻辑在于消除对人工特征工程的依赖。该方法将原始网络流或会话的前 784 个字节视作一维序列输入。截取一个流的前 784 个字节的有效载荷，并将其映射至灰度值范围，构造成灰度图

像形式，接着利用卷积层和池化层自动、逐层地提取流量中的非线性空间特征，并最终在深度学习框架下实现从原始报文到业务类型的端到端映射与分类。

(2) **DM-HNN**: DM-HNN 模型是当前加密流量分类中特征融合路径的典型代表。其核心设计逻辑在于利用双模态特征克服单一特征源的信息缺失问题：该模型通过对门控循环单元 (GRU) 进行改进，在 GRU 层之间引入信息传输通道从而解决梯度回流受阻问题，并使用改进的 GRU 路径对流级别特征进行处理。接着利用堆叠自编码器 (SAE) 对数据包有效载荷字节进行空间建模，使用三角函数对字节的位置信息进行编码，融合将编码后的向量输入多层 SAE 中提取包级别的流量特征。最后将两种流量进行拼接，实现融合特征的提取。我们将遵循原作者的架构设置，将两路特征进行分别提取拼接后输入分类器完成分类任务。

(3) **Ours-onlyp**: 为了验证本章提出的融合机制有效性以及两种模态特征存在的互补优势。我们设计了一个仅使用本章开头提取的包级别特征作为最终分类特征的消融版本。该版本将不涉及流级别特征以及注意力融合机制，仅使用 n-gram 嵌入处理后的包级别特征作为分类器输入，同时保持分类器的各项设置不变。通过与该版本的对比，我们能够进一步量化融合特征机制在提升模型性能方面的作用。

4.6.3 实验结果分析

在本节中，我们将对所提出的基于融合特征的流量分类模型与上述几种对比算法在多个数据集上的实验结果进行详细分析。具体的各项实验结果数据如表 4.3 所示，其中 Precision, Recall, F1-Score 的值为每一个类别对应值的平均数。

从整体实验数据来看，本章提出的基于融合特征的分类方法在四个公开数据集中表现出了显著的优越性。在绝大多数分类指标上均取得了最优结果。特别是在识别难度较高的 ISCX-VPNnonVPN 数据集上，本文方法的准确率达到了 97.85%，相比于基准方法 1D-CNN 提升了约 11.06%，在 F1-Score 上也保持了极高的一致性。即使在流量混淆特征极强的 VNAT 数据集中，本文方法依然能够达到 98.30% 的准确率，这充分证明了该模型在面对复杂、非对称且高度加密的网络环境时，具备极强的分类鲁棒性和泛化能力。在恶意流量数据集 USTC-TFC 上，本文方法与目前领先的双模态方法 DM-HNN 性能基本持平，准确率均突破了 99.5%，显示出该架构在处理不同性质的加密流量任务时均具有极高的适配性。

深入对比单模态与双模态特征的实验表现可以发现，多模态特征的引入是提升加密流量分类性能的关键。传统的单模态方法如 1D-CNN 仅依赖于数据包有效载荷载荷，在面对现代加密技术带来的流量随机化挑战时，往往因特征表达能力不足而陷入性能瓶颈。相比之下，DM-HNN 以及本文提出的双模态融合框

数据集	方法	Accuracy	Precision	Recall	F1-Score
ISCX-VPNnonVPN	1D-CNN	86.79%	86.59%	86.69%	86.60%
	DM-HNN	93.37%	93.43%	93.44%	93.31%
	Ours-onlyp	92.28%	92.31%	92.28%	92.23%
	Ours	97.85%	97.85%	97.86%	97.84%
ISCX-TornonTor	1D-CNN	88.04%	88.36%	88.05%	88.16%
	DM-HNN	91.90%	91.86%	91.95%	91.89%
	Ours-onlyp	90.81%	90.78%	90.80%	90.78%
	BYOL-Ours	94.13%	94.14%	94.13%	94.12%
USTC-TFC	1D-CNN	97.50%	97.51%	97.54%	97.50%
	DM-HNN	99.62%	99.62%	99.63%	99.62%
	Ours-onlyp	98.12%	98.18%	98.11%	98.12%
	BYOL-Ours	99.51%	99.51%	99.51%	99.51%
VNAT	1D-CNN	93.20%	92.80%	92.79%	92.62%
	DM-HNN	95.01%	93.95%	95.72%	94.29%
	Ours-onlyp	94.90%	95.03%	94.87%	94.80%
	BYOL-Ours	98.30%	98.39%	98.26%	98.31%

表 4.3 不同数据集上的对比实验结果

架通过同时捕获时序流向的流级别特征与报文内容的包级别特征，有效地实现了信息的维度互补。实验数据清晰地表明，在所有数据集中，双模态方法的性能指标均大幅度领先于单模态方法，这印证了多模态特征挖掘能够通过捕捉更深层次的数据流行为模式，从而显著降低分类器的误报率并提升对复杂加密隧道流量的识别精度。

此外，本文设计的特征融合策略与 BYOL 自监督学习框架进一步增强了特征的判别性。通过对比同为双模态架构的 DM-HNN 可以观察到，本文方法在 VNAT 和 ISCX-VPN 等数据集上展现出了更优的特征表现，这得益于模型内部能够更深入地建模不同模态间的非线性关联。同时，消融实验结果进一步揭示了多尺度表征的重要性。实验显示，仅使用包级别特征的 Ours-onlyp 版本在各项指标上均明显低于完整版模型，例如在 ISCX-VPNnonVPN 中，完整版比消融版准确率高出 5.57%。这有力地证明了流级别与包级别特征之间存在显著的协同效应，只有通过深层的特征融合，才能在保持局部细节感知的同步实现对全局长时序行为的精准刻画，从而达成最优的分类效果。

此外，针对本章开头提到的类别混淆问题，我们还对各个类别的分类结果提取了混淆矩阵。以类别混淆问题最为严重的 VNAT 数据集为例，图 4.5 中分别

Normalized Confusion Matrix (row-wise):						Normalized Confusion Matrix (row-wise):						Normalized Confusion Matrix (row-wise):					
	chat	file	streaming	VoIP	C2		chat	file	streaming	VoIP	C2		chat	file	streaming	VoIP	C2
chat	100.0%	0.0%	0.0%	0.0%	0.0%	chat	86.6%	0.0%	0.0%	4.1%	9.3%	chat	100.0%	0.0%	0.0%	0.0%	0.0%
file	0.0%	99.5%	0.5%	0.0%	0.0%	file	0.0%	95.4%	0.5%	1.0%	3.1%	file	0.0%	96.4%	3.6%	0.0%	0.0%
streaming	0.0%	0.5%	98.2%	0.9%	0.5%	streaming	0.9%	3.2%	95.0%	0.0%	0.9%	streaming	0.0%	0.0%	100.0%	0.0%	0.0%
VoIP	0.0%	0.0%	0.0%	100.0%	0.0%	VoIP	0.0%	0.0%	0.0%	100.0%	0.0%	VoIP	0.0%	2.5%	0.0%	97.5%	0.0%
C2	0.0%	48.4%	1.1%	0.0%	50.5%	C2	1.1%	0.5%	0.0%	1.1%	97.4%	C2	0.5%	0.5%	1.1%	0.5%	97.4%

图 4.5 三种模型的混淆矩阵

为：（1）仅使用前 16 个数据包长度序列作为原始特征输入 BYOL 模型的流级别特征分类结果。（2）仅使用包级别特征作为分类特征的分类结果。（3）使用融合特征作为最终分类特征的分类结果。

仅使用流级别特征的方法在对常规业务如 chat 和 VoIP 具有极高的识别率，但在处理 C2 流量时存在严重的误判现象约有 48.4% 的 C2 流量被错误地识别为 file 传输。这表明单一的流级别长度序列在面对具有相似突发性行为的加密流量时，容易产生特征重叠，无法有效提取区分命令控制与文件传输的微观指纹。而仅使用包级别特征的分类结果，在 C2 流量上的识别精度有了显著提升，但是在 chat 类别上却表现出性能退化，有约 9.3% 的 chat 流量被误分类为 C2。这说明虽然包级别的深层特征对于捕捉特定的应用层行为非常有效，但在缺乏宏观流行行为的约束下，容易将一些短小频繁的即时通讯包误判为控制指令。

而使用融合特征的分类模型有效地结合了两者的优势，补齐了单一模态的性能短板。在融合特征下，chat 和 streaming 的识别率均达到了 100%，同时 C2 流量的识别率维持在 97.4% 的高水准，且原本在包级别特征中出现的 chat 误判为 C2 的现象得到了根本性抑制。这组对比实验有力地证明了：流级别特征提供了宏观的业务框架约束，而包级别特征提供了微观的业务指纹校验，两者的深度融合能够显著消除特定类别间的混淆问题，使模型在多业务共存的复杂网络流量中展现出更精准的分类性能。

4.7 本章小结

在本章中，我们详细介绍了本文提出的双模态融合特征分类方法，旨在通过整合流级行为特征与包级协议结构特征，提升加密网络流量识别的精确度与鲁棒性。该方法充分利用了前两章在自监督学习与特征提取方面的研究成果，构建了一个协同增强的分类框架。

首先，本章阐述了双模态特征的构建与处理流程。我们通过第三章设计的 BYOL 自监督模型提取具有强鲁棒性的流级特征向量，同时截取网络流中关键报文的头部字节作为包级特征。针对这两种模态在维度与语义空间上的差异，本章设计了专门的特征融合层。该层采用逐层特征升维与非线性映射策略，将来自不同维度的特征投影至统一的高维表征空间，并通过残差连接机制有效缓解了深层网络训练中的退化问题，确保了多源信息在融合过程中的完整性与互补性。

随后，本章深入探讨了融合模型的分类架构与训练策略。分类器部分采用了多层全连接网络，配合 AdamW 优化器与指数移动平均（EMA）权重更新机制，进一步提升了模型在复杂数据集上的收敛速度与泛化能力。为了验证双模态融合的有效性，我们在 ISCX-VPNnonVPN、ISCX-TorNonTor 等四个主流公开数据集上进行了详尽的对比实验。

实验结果表明，本文提出的双模态融合模型在各项评价指标上均取得了最优表现。相比于单一的流级特征或包级特征模型，融合模型在处理高度混淆的匿名流量与隧道流量时展现出更强的判别性能，准确率较对比算法实现了显著提升。这充分证明了流级行为序列与包级协议结构在加密流量识别任务中具有显著的协同效应，为实现高效、精准的加密网络流量监控提供了可靠的技术方案。

第5章 总结与展望

5.1 本文工作总结

本文针对当前网络环境下加密流量普及带来的监管难题，深入探讨了基于自监督学习与多模态特征融合的加密流量分类技术。随着传输层安全协议及各类混淆技术的广泛应用，传统的基于报文载荷检测的手段已难以发挥作用，而单一维度的统计特征在面对 VPN、Tor 等隧道加密流量时往往表现出判别力不足的问题。本研究立足于提升特征表示的鲁棒性与分类模型的泛化能力，从理论基础、单模态自监督学习模型构建到双模态融合框架的设计，展开了系统性的研究工作。

研究的第一阶段，我们对网络流量分类的演进历程及深度学习相关理论进行了详尽梳理。通过分析发现，深度学习虽然能够减少人工特征工程的负担，但在有标签数据匮乏的实际场景中容易陷入过拟合。为此，本文引入了自监督学习中的对比学习范式，为后续无需海量标注数据即可提取核心语义特征奠定了理论基石。在第二章中，我们重点研究了卷积神经网络与残差结构的结合，以及注意力机制在捕捉流量时空关联性中的重要作用，这些理论的积淀直接指导了后续模型的设计方向。

研究的第二阶段，本文提出并实现了一种基于 BYOL 架构的流级别特征分类方法。针对加密流量在真实物理网络中存在的丢包、乱序、重传以及由于 MTU 限制和协议栈填充导致的长度波动等现象，本研究专门设计了噪声注入、尺度缩放与随机遮蔽等增强函数。通过构建非对称的在线网络与目标网络，并采用指数移动平均（EMA）更新机制，模型能够从差异化的流量变体中自动捕捉不随网络环境改变的本质规律。实验结果在 ISCX-VPNnonVPN、ISCX-TorNonTor 等数据集上得到了验证，证明了该自监督模型在不依赖负样本的情况下，能够有效克服表征崩溃问题，并赋予了流级特征更强的环境适应性。

研究的第三阶段，本文进一步突破单一模态的局限，构建了双模态融合特征分类框架。本阶段研究发现，流级行为序列反映了流量的宏观统计分布，而包级协议结构特征则隐藏了微观的交互逻辑。通过将 BYOL 模型提取的流级鲁棒特征与关键报文头部字节的包级特征进行融合，并设计专门的特征融合层进行非线性映射与空间对齐，模型实现了多源信息的协同增强。在针对高度混淆流量的分类测试中，该融合模型表现出了超越单一模态模型的分类精度，准确率较传统算法和基础深度学习模型均有显著提升。这表明，通过对流量行为与协议结构的双重建模，能够有效过滤加密层带来的噪声干扰，挖掘出加密隧道下的真实应用

意图。

综上所述，本文的研究工作构建了一套从原始流量采集、自监督特征学习到多模态特征融合的完整加密流量分类体系。本研究不仅在理论上探索了自监督学习在网络安全领域的应用边界，更在实践中证明了融合特征在应对复杂加密环境时的卓越性能，为维护网络空间安全、实现精细化流量管控提供了科学的参考依据与技术支持。

5.2 未来展望

尽管本文在加密流量分类领域取得了一定的研究成果，但在应对日益动态化、智能化和极大规模化的网络环境时，仍存在许多值得深入探索的方向。未来的研究工作可以从以下几个维度展开。

首先，模型在异构网络环境下的领域自适应能力有待进一步加强。本研究主要基于公开数据集进行实验验证，虽然这些数据集涵盖了多种典型的加密应用场景，但真实生产环境中的流量分布往往具有显著的时变性和地域性。不同网络供应商、不同终端设备产生的流量特征可能存在较大偏差。未来的工作可以引入迁移学习或领域自适应（Domain Adaptation）技术，探索如何利用少量目标域数据对预训练模型进行快速微调，使模型能够在动态变化的现网环境中保持长期稳定的分类性能。

其次，针对对抗样本攻击的鲁棒性研究将是另一个关键领域。随着人工智能技术在攻防两端的同步演进，攻击者可能会通过在流量包中注入特定比例的干扰报文、动态调整包长度或伪造心跳包等手段，实施针对深度学习分类器的对抗攻击。目前我们的模型虽然通过数据增强提升了对环境噪声的抵抗力，但尚未针对恶意构造的对抗样本进行系统性的防御设计。未来可以考虑引入对抗训练策略，在训练过程中主动加入对抗样本，以增强模型在极端对抗环境下的安全性。

再者，模型的可解释性与轻量化部署是走向工业化应用的必经之路。深度学习模型常被视为“黑盒”，在安全审查和故障溯源时难以给出直观的判断依据。未来研究可以结合集成学习或显著性图分析技术，分析不同模态特征对分类决策的贡献度，从而提高模型的可信度。同时，考虑到骨干网络 1D-CNN 和融合层带来的计算开销，探索知识蒸馏、模型剪枝等轻量化技术，实现在边缘设备或高性能路由器上的实时流量检测，具有重要的工程价值。

最后，多模态特征的挖掘范围仍有扩展空间。本文目前主要融合了包长度序列与报文头部字节，未来可以进一步引入流量到达时间间隔（IAT）、TLS 握手阶段的明文指纹信息（如 Cipher Suites、Extensions）以及 DNS 关联查询等多维数据。通过构建更大规模、跨协议栈的全空间特征图谱，有望实现对更隐蔽、更复

杂混淆技术的精准识别。此外，探索大语言模型（LLM）在协议语义理解中的潜力，或许能为流量分类领域带来范式上的创新。

第 6 章 引用文献的标注

模板使用 **natbib** 宏包来设置参考文献引用的格式，更多引用方法可以参考该宏包的使用说明。

6.1 顺序编码制

6.1.1 角标数字标注法

<code>\cite{knuth86a}</code>	$\Rightarrow$	[1]
<code>\citet{knuth86a}</code>	$\Rightarrow$	Knuth ^[1]
<code>\cite[42]{knuth86a}</code>	$\Rightarrow$	[1] ⁴²
<code>\cite{knuth86a,tlc2}</code>	$\Rightarrow$	[1-2]
<code>\cite{knuth86a, knuth84}</code>	$\Rightarrow$	[1,3]

6.1.2 数字标注法

<code>\cite{knuth86a}</code>	$\Rightarrow$	[1]
<code>\citet{knuth86a}</code>	$\Rightarrow$	Knuth [1]
<code>\cite[42]{knuth86a}</code>	$\Rightarrow$	[1] ⁴²
<code>\cite{knuth86a,tlc2}</code>	$\Rightarrow$	[1-2]
<code>\cite{knuth86a, knuth84}</code>	$\Rightarrow$	[1, 3]

6.2 著者-出版年制标注法

<code>\cite{knuth86a}</code>	$\Rightarrow$	Knuth (1986)
<code>\citep{knuth86a}</code>	$\Rightarrow$	(Knuth, 1986)
<code>\citet[42]{knuth86a}</code>	$\Rightarrow$	Knuth (1986) ⁴²
<code>\citep[42]{knuth86a}</code>	$\Rightarrow$	(Knuth, 1986) ⁴²
<code>\cite{knuth86a,tlc2}</code>	$\Rightarrow$	Knuth (1986); Mittelbach et al. (2004)
<code>\cite{knuth86a, knuth84}</code>	$\Rightarrow$	Knuth (1986, 1984)

参考文献

- [1] Knuth D E. Computers and typesetting: A the $\text{\TeX}$ book[M]. Reading, MA, USA: Addison-Wesley, 1986.
- [2] Mittelbach F, Goossens M, Braams J, et al. The $\text{\LaTeX}$ companion[M]. 2nd ed. Reading, MA, USA: Addison-Wesley, 2004.
- [3] Knuth D E. Literate programming[J]. The Computer Journal, 1984, 27(2): 97-111.
- [4] Lamport L. $\text{\LaTeX}$: a document preparation system[M]. 2nd ed. Reading, MA, USA: Addison-Wesley, 1994.
- [5] 孙立广. 极地科学前沿与热点: 顶级期刊论文摘要汇编(1999—2010) [M]. 合肥: 中国科学技术大学出版社, 2016: 222.
- [6] 李永池. 张量初步和近代连续介质力学概论[M]. 2 版. 合肥: 中国科学技术大学出版社, 2016: 61.
- [7] 刘景双. 湿地生态系统碳、氮、硫、磷生物地球化学过程[M]. 合肥: 中国科学技术大学出版社, 2014.
- [8] Crawford W, Gorman M. Future libraries: Dreams, madness, & reality[M]. Chicago: American Library Association, 1995.
- [9] International Federation of Library Association and Institutions. Names of persons: National usage for entry in catalogues[M]. 3rd ed. London: IFLA International Office for UBC, 1977.
- [10] 程根伟. 1998 年长江洪水的成因与减灾对策[M]//许厚泽, 赵其国. 长江流域洪涝灾害与科技对策. 北京: 科学出版社, 1999: 26-32.
- [11] 陈晋镛, 张惠民, 朱士兴, 等. 蓟县震旦亚界研究[M]//中国地质科学院天津地质矿产研究所. 中国震旦亚界. 天津: 天津科学技术出版社, 1980: 56-114.
- [12] Buseck P R, Nord G L, Jr., Veblen D R. Subsolidus phenomena in pyroxenes[M]//Prewitt C T. Pyroxenes. Washington, D.C.: Mineralogical Society of America, 1980: 117-212.
- [13] Fournay M E. Advances in holographic photoelasticity[C]//American Society of Mechanical Engineers. Applied Mechanics Division. Symposium on Applications of Holography in Mechanics, August 23-25, 1971, University of Southern California, Los Angeles, California. New York: ASME, 1971: 17-38.
- [14] 孔庆勇, 郭红健, 孔庆和. 我国科技期刊的金字塔分层模型及发展路径初探[J]. 中国科技期刊研究, 2015, 26(10): 1100-1103.
- [15] 杨洪升. 四库馆私家抄校书考略[J]. 文献, 2013(1): 56-75.
- [16] 于潇, 刘义, 柴跃廷, 等. 互联网药品可信交易环境中主体资质审核备案模式[J]. 清华大

- 学学报 (自然科学版), 2012, 52(11): 1518-1521.
- [17] Des Marais D J, Strauss H, Summons R E, et al. Carbon isotope evidence for the stepwise oxidation of the proterozoic environment[J]. *Nature*, 1992, 359: 605-609.
- [18] HEWITT J A. Technical services in 1983[J]. *Library Resource Services*, 1984.
- [19] 丁文详. 数字革命与竞争国际化[N]. *中国青年报*, 2000-11-20(15).
- [20] 姜锡洲. 一种温热外敷药制备方案: 88105607.3[P]. 1989-07-26.
- [21] 万锦坤. 中国大学学位论文文摘 (1983-1993) (英文版) [DB/CD]. 北京: 中国大百科全书出版社, 1996.
- [22] Mlot C. Plant physiology: Plant biology in the Genome Era[J]. *Science*, 1998, 281: 331-332.
- [23] 孙玉文. 汉语变调构词研究[D]. 北京: 北京大学, 2000.
- [24] Cairns B R. Infrared spectroscopic studies of solid oxygen[D]. Berkeley: Univ. of California, 1965.
- [25] 中国力学学会. 第3届全国实验流体力学学术会议论文集[C]. 天津, 1990.
- [26] Rosenthal E M. Proceedings of the Fifth Canadian Mathematical Congress, University of Montreal, 1961[C]. Toronto: University of Toronto Press, 1963.
- [27] Baker S K, Jackson M E. The future of resource sharing[M]. New York: The Haworth Press, 1995.
- [28] 尼葛洛庞帝. 数字化生存[M]. 胡泳, 范海燕, 译. 海口: 海南出版社, 1996.
- [29] 杨宗英. 电子图书馆的现实模型[J]. *中国图书馆学报*, 1996(2): 24-29.
- [30] 刘斌. 力学[M]. 合肥, 2014: 24-29.
- [31] 刘文富, 顾丽梅. 网络时代经济发展战略特征[J]. *学术研究*, 2000, 21(4): 35-40.
- [32] 肖渡, 沈群红, 张芸, 等. 知识时代的企业合作经营[M]. 北京: 北京大学出版社, 2000: 67-69.
- [33] The White House. Technology for economic growth[R]. Washington, 1993.
- [34] Hutson J M. Vibrational dependence of the anisotropic intermolecular potential of argon-hydrogen chloride[J]. *J. Phys. Chem.*, 1992, 96(11): 4237-4247.

在读期间取得的科研成果

已发表论文:

- [1] 2025 年以第一作者身份在 2025 IEEE 24th International Conference on Trust, Security and Privacy in Computing and Communications (TrustCom) 发表论文一篇